

Géoépidémiologie et Analyse Spatiale avec R

Guide Méthodologique Complet et Exhaustif

Cartographie · Autocorrélation Spatiale · Détection de
Clusters · Hotspots

Lionel AGOSSOU

Épidémiologiste | Biostatisticien | Formateur en Analyse de Données Biomédicales

Packages R utilisés :

geodata · sf · spdep · spatialreg · tmap · leaflet · ggplot2 · sfdep

TABLE DES MATIÈRES

1. Introduction à la Géoépidémiologie Spatiale.....	5
2.1 La Première Loi de Tobler et l'Autocorrélation Spatiale.....	7
2.2 La Matrice de Contiguïté et les Poids Spatiaux.....	8
2.3 Le Problème de la Variation Aléatoire en Petites Aires.....	9
3. Importation des Données Spatiales avec gadm.....	10
3.1 Présentation du Package geodata.....	10
3.2 Installation et Chargement des Packages.....	10
3.3 Importation des Géométries du Bénin via gadm.....	11
4. Cartographie des Maladies.....	14
4.1 Principes de la Cartographie Sanitaire.....	15
4.2 Discrétisation des Données : Méthodes de Classification.....	16
4.3 Cartographie Choroplèthe avec tmap.....	17
4.4 Cartographie Comparative Multi-Maladies avec patchwork.....	19
4.5 Carte Interactive avec Leaflet.....	21
4.6 Cartographie avec ggplot2 : Niveau Expert.....	23
5. Autocorrélation Spatiale : I de Moran et LISA.....	25
5.1 Construction de la Matrice de Poids Spatiaux avec spdep.....	25
5.2 L'Indice de Moran Global (I de Moran).....	26
5.2.1 Fondements Mathématiques.....	26
5.3 Les Indicateurs Locaux d'Association Spatiale (LISA).....	29
5.3.1 Principe et Formulation.....	29
5.3.2 Cartographie des LISA : Cluster Map.....	31
5.3.3 Interprétation des Résultats LISA.....	32
5.4 Analyse de Sensibilité : Impact du Choix des Poids Spatiaux.....	33
6. Détection de Clusters et Hotspots.....	34
6.1 Panorama des Méthodes de Détection de Clusters.....	34

6.2 La Statistique de Getis-Ord G_i^* (G-star)	35
6.3 Lissage par Noyau Spatial (Kernel Density Estimation)	38
6.4 Détection de Clusters par la Méthode de Kulldorff (SpatialEpi).....	40
6.5 Tableau de Synthèse des Méthodes de Détection	43
7.1 Lissage Empirique Bayésien (EB) de Marshall-Cressie	45
7.2 Tableau de Bord Spatial : Synthèse Publication-Ready	46
8.1 Principales Erreurs à Éviter	49
8.2 Check-list de Validation de l'Analyse Spatiale	49
4bis. Cartographie des Maladies — Traitement Exhaustif	50
4bis.1 Sémiologie Graphique en Cartographie Sanitaire	50
4bis.2 Taxonomie Complète des Types de Cartes en Santé Publique	51
4bis.2.1 Principes avancés de la Carte Choroplèthe	51
4bis.2.2 Cartes de Symboles Proportionnels.....	51
4bis.2.3 Cartogrammes (Gastner-Newman et Dorling)	52
4bis.2.4 Cartes de Risque Relatif Standardisé (SIR/SMR).....	53
4bis.2.5 Cartes de Flux et Diffusion Spatiale	53
4bis.2.6 Cartes Spatio-Temporelles et Animations gganimate	54
4bis.2.7 Cartes de Surveillance Syndromique et Tableaux de Bord Shiny	55
4bis.2.8 Systèmes de Projection — Guide Complet	56
10. Modeles Spatiaux Avancés — Régression et Interpolation.....	58
10.1 Diagnostic Spatial Préalable : Tests de Lagrange Multiplier.....	58
10.2 Modèle SAR — Spatial Autoregressive (Spatial Lag Model).....	59
10.3 Modèle SEM — Spatial Error Model	59
10.4 Modèle de Durbin Spatial (SDM).....	60
10.5 Modèle SLX — Spatially Lagged X.....	61
10.6 Régression Géographiquement Pondérée (GWR)	61
10.7 Modèle BYM Bayésien avec CARBayes	63

10.8 Modèle BYM2 avec R-INLA	64
10.9 Krigeage et Interpolation Géostatistique	65
10.10 Tableau Comparatif de Tous les Modèles Spatiaux	67
11. Conclusion	68

1. Introduction à la Géoépidémiologie Spatiale

La géoépidémiologie est la branche de l'épidémiologie qui intègre explicitement la dimension spatiale dans l'analyse de la distribution, des déterminants et de la dynamique des maladies dans les populations. Elle part d'un constat fondamental formulé dès 1854 par John Snow lors de l'épidémie de choléra à Londres : la localisation géographique des cas de maladie n'est pas aléatoire, elle porte une information épidémiologique de premier ordre sur les sources d'exposition, les vecteurs, et les populations à risque.

Dans les contextes de santé publique africains et, plus particulièrement, dans le système de santé béninois, l'analyse spatiale revêt une importance stratégique. Les maladies tropicales négligées, le paludisme, la méningite, la fièvre typhoïde et les maladies diarrhéiques présentent des distributions spatiales profondément hétérogènes, conditionnées par des déterminants géographiques (hydrographie, végétation, altitude), environnementaux (température, précipitations, humidité) et socio-économiques (densité de population, accès aux soins, niveau d'instruction). Ignorer cette dimension spatiale conduit inévitablement à des estimations biaisées des risques et à des interventions de santé publique mal ciblées.

Ce guide méthodologique couvre de façon exhaustive les trois piliers de l'analyse géoépidémiologique avec R : la cartographie sanitaire à partir de données de forme récupérées via le package `gadm`, l'autocorrélation spatiale globale et locale (indices de Moran global et local, statistique LISA), et la détection de clusters et de hotspots (statistique de scan spatiale de Kulldorff, méthodes de lissage par noyau, méthodes SaTScan). Chaque section est illustrée par du code R directement exécutable, annoté et commenté, appliqué aux données de santé publique du Bénin.

i Objectifs pédagogiques de ce guide

- *Maîtriser l'importation et la manipulation des données spatiales vectorielles (`shapefiles`) via le package `gadm` et `sf`.*
- *Produire des cartes choroplèthes et de densité de cas de qualité publication avec `tmap` et `ggplot2`.*
- *Comprendre et calculer l'autocorrélation spatiale globale (*I* de Moran) et locale (LISA) avec `spdep`.*

- Détecter et cartographier les clusters spatiaux et hotspots de maladies avec *sfdep* et *KernSmooth*.
- Interpréter correctement les résultats et les présenter selon les standards éditoriaux en géoépidémiologie.
- Éviter les erreurs fréquentes : MAUP, poids spatiaux, corrections de tests multiples, interprétation causale abusive.

2. Fondements Théoriques de l'Analyse Spatiale en Épidémiologie

2.1 La Première Loi de Tobler et l'Autocorrélation Spatiale

La première loi de géographie, formulée par Waldo Tobler en 1970, est le fondement théorique de toute l'analyse spatiale : "Toutes les choses sont reliées entre elles, mais les choses proches sont plus liées que les choses éloignées." En géoépidémiologie, cette loi se traduit par le fait que l'incidence d'une maladie dans une zone géographique est statistiquement associée à l'incidence dans les zones voisines. Ce phénomène est appelé autocorrélation spatiale positive lorsque les valeurs élevées sont entourées de valeurs élevées et les valeurs faibles de valeurs faibles, et autocorrélation spatiale négative lorsque les valeurs élevées alternent avec des valeurs faibles.

L'autocorrélation spatiale a des implications méthodologiques majeures pour l'analyse épidémiologique. En statistique classique, l'hypothèse d'indépendance des observations est fondamentale. Lorsque les données présentent une autocorrélation spatiale, cette hypothèse est violée : les observations proches se ressemblent plus que ne le prédirait le hasard. Cela conduit à une sous-estimation des erreurs standard dans les modèles de régression ordinaires, à une inflation du taux de faux positifs dans les tests statistiques classiques, et à une inefficacité des estimateurs des moindres carrés ordinaires (MCO).

Concept	Définition	Implication épidémiologique
Autocorrélation spatiale positive	Valeurs similaires groupées dans l'espace	Clusters de maladies, contagion spatiale
Autocorrélation spatiale négative	Valeurs dissimilaires alternent dans l'espace	Compétition entre zones, diffusion par déplacement
Stationnarité spatiale	La structure spatiale est constante sur la zone	Validité des indices globaux comme le I de Moran
Non-stationnarité	La structure varie selon la sous-région	Nécessite des indices locaux (LISA, GWR)

Concept	Définition	Implication épidémiologique
Effet MAUP	Les résultats dépendent du découpage spatial choisi	Choisir le découpage pertinent épidémiologiquement
Zone d'étude optimale	La définition des frontières affecte les résultats	Problème des unités spatiales modifiables

2.2 La Matrice de Contiguïté et les Poids Spatiaux

La matrice de poids spatiaux W est la pièce maîtresse de tout calcul d'autocorrélation spatiale. Elle encode formellement la structure de voisinage entre les unités spatiales (communes, districts, départements). Pour n unités spatiales, W est une matrice $n \times n$ dont l'élément w_{ij} représente le "lien spatial" entre l'unité i et l'unité j . Plusieurs critères de définition de cette matrice existent, chacun reflétant une conceptualisation différente de la proximité spatiale.

La contiguïté de la Reine (Queen contiguity) considère comme voisines toutes les unités partageant au moins un point de frontière commun (y compris les coins), ce qui est le critère le plus permissif. La contiguïté de la Tour (Rook contiguity) ne retient comme voisines que les unités partageant un segment de frontière commun (frontière linéaire), excluant les contacts par un seul point. La distance euclidienne définit les voisins comme toutes les unités dont le centroïde se trouve dans un rayon d prédéfini. Les k plus proches voisins retiennent pour chaque unité ses k unités les plus proches (critère non symétrique). Le choix entre ces critères doit être guidé par la structure géographique du territoire étudié et la question épidémiologique posée.

i Formalisation de la matrice de poids W

→ $w_{ij} = 1$ si les unités i et j sont voisines selon le critère choisi, $w_{ij} = 0$ sinon (y compris pour $w_{ii} = 0$).

→ La matrice W est ensuite standardisée en lignes : $w_{ij}^* = w_{ij} / \sum_j w_{ij}$, de sorte que la somme de chaque ligne vaut 1.

- Cette standardisation garantit que la moyenne spatiale pondérée est une combinaison convexe des valeurs voisines.
- Le choix du critère de voisinage est une décision analytique fondamentale qui doit être justifiée et testée en analyse de sensibilité.

2.3 Le Problème de la Variation Aléatoire en Petites Aires

Un problème fondamental en cartographie des maladies en petites aires est la variabilité aléatoire excessive des taux bruts dans les zones à faible population. Dans une commune de 500 habitants, un seul cas supplémentaire fait varier le taux de 2,0 pour 1000 à 4,0 pour 1000 — une apparente multiplication par deux qui n'est en réalité que du bruit aléatoire. Ce phénomène rend les cartes de taux bruts très difficiles à interpréter épidémiologiquement, car les zones les plus petites apparaissent artificiellement comme les plus « extrêmes » (les plus élevées et les plus basses).

La solution standard consiste à utiliser des estimateurs lissés : le lissage empirique bayésien (EB) de Marshall (1991) et de Cressie (1993), les modèles conditionnellement autorégressifs (CAR) et les modèles intrinsèquement autorégressifs (ICAR) qui empruntent de l'information aux zones voisines, et les méthodes non paramétriques de lissage par noyau spatial. Ces approches permettent de produire des cartes qui distinguent efficacement le signal épidémiologique du bruit aléatoire.

3. Importation des Données Spatiales avec gadm

3.1 Présentation du Package geodata

Le package geodata est la référence pour l'importation de données administratives spatiales vectorielles directement dans R, sans avoir à télécharger manuellement des fichiers shapefile. Il s'interface avec la base de données GADM (gadm.org) qui fournit les frontières administratives de tous les pays du monde à différents niveaux hiérarchiques (pays, régions, départements, communes, etc.). Pour le Bénin, le découpage GADM distingue trois niveaux : niveau 0 (frontières nationales), niveau 1 (départements : 12 départements), et niveau 2 (communes : 77 communes).

i Niveaux administratifs GADM pour le Bénin

- *Level 0 (country) : frontières nationales du Bénin — 1 entité.*
- *Level 1 (region/dept) : 12 départements — Alibori, Atacora, Atlantique, Borgou, Collines, Couffo, Donga, Littoral, Mono, Ouémé, Plateau, Zou.*
- *Level 2 (district/commune) : 77 communes — découpage le plus fin disponible dans GADM.*
- *Les géométries sont renvoyées au format sf (Simple Features) compatible avec l'écosystème spatial moderne de R.*

3.2 Installation et Chargement des Packages

Commençons par installer et charger l'ensemble des packages nécessaires à l'analyse géoépidémiologique complète :

```
# — Installation des packages nécessaires  
# (à exécuter une seule fois)  
install.packages(c("gedodata", "sf", "spdep", "sfdep",  
"tmap", "ggplot2",  
"leaflet", "spatialreg", "KernSmooth",  
"RColorBrewer",  
"viridis", "dplyr", "tidyr",  
"patchwork", "gtsummary",
```

```

      "flextable", "scales", "classInt"))

# ——— Chargement des packages


---


library(geodata)      # Importation des données GADM
library(sf)           # Manipulation des données spatiales
library(spdep)        # Poids spatiaux et autocorrélation
library(sfdep)        # Interface tidy pour spdep
library(tmap)         # Cartographie thématique
library(ggplot2)      # Visualisation avancée
library(leaflet)      # Cartes interactives
library(spatialreg)   # Modèles de régression spatiale
library(KernSmooth)   # Lissage par noyau spatial
library(RColorBrewer) # Palettes de couleurs cartographiques
library(viridis)      # Palettes perceptuellement uniformes
library(dplyr)        # Manipulation de données
library(classInt)     # Discrétisation pour cartographie

# ——— Options globales


---


options(scipen = 999) # Désactiver la notation
scientifique
set.seed(2024)        # Reproductibilité

```

3.3 Importation des Géométries du Bénin via gadm

La fonction principale du package `gadm` est `gadm()` qui télécharge et renvoie les données GADM sous forme d'objet `sf` directement utilisable dans R :

‘marginaleffects’, ‘lifecycle’, ‘rlang’, ‘vctrs’, ‘cards’, ‘cardx’, ‘gdtools’, ‘officer’

```

# ——— Importation des niveaux administratifs du Bénin


---



# Niveau 0 : frontières nationales
benin_pays <- gadm(country = "BEN", level = 0, path =
tempdir())

```

```

benin_pays <- st_as_sf(benin_pays) # Conversion en objet
sf

# Niveau 1 : 12 départements
benin_dept <- gadm(country = "BEN", level = 1, path =
tempdir())
benin_dept <- st_as_sf(benin_dept)

# Niveau 2 : 77 communes
benin_commune <- gadm(country = "BEN", level = 2, path =
tempdir())
benin_commune <- st_as_sf(benin_commune)

# — Inspection des objets sf
_____

cat('Système de coordonnées de référence (CRS) :\n')
print(st_crs(benin_commune)$input) # WGS84 par défaut dans
GADM

cat('\nNombre d\'entités par niveau :\n')
cat(' - Pays      : ', nrow(benin_pays),      '\n')
cat(' - Départements : ', nrow(benin_dept),    '\n')
cat(' - Communes : ', nrow(benin_commune), '\n')

# — Noms des colonnes disponibles
_____

names(benin_commune)

```

Le package `gadm` renvoie un objet `sf` (Simple Features) avec le système de coordonnées WGS84 (EPSG:4326). Pour les calculs de superficie et de distance, il convient de reprojeter en un système de coordonnées projeté adapté à l'Afrique de l'Ouest.

```

# — Reprojection en Lambert Azimuthal Equal Area (LAEA)
Afrique _____
# EPSG:102022 — système adapté à l'Afrique de l'Ouest pour
les mesures

benin_dept_proj <- st_transform(benin_dept, crs =
32631) # UTM 31N

```

```

benin_commune_proj <- st_transform(benin_commune, crs =
32631)

# — Calcul des superficies (en km²)
_____

benin_commune_proj$superficie_km2 <-
as.numeric(st_area(benin_commune_proj)) / 1e6

# — Calcul des centroïdes
_____

centroïdes <- st_centroid(benin_commune_proj)
centroïdes_coords <- st_coordinates(centroïdes)
benin_commune_proj$lon_centroïde <- centroïdes_coords[, 1]
benin_commune_proj$lat_centroïde <- centroïdes_coords[, 2]

cat('Superficie totale du Bénin (km²) :',
    round(sum(benin_commune_proj$superficie_km2), 0), '\n')

```

3.4 Fusion des Données Épidémiologiques avec les Géométries

Dans la pratique, les données épidémiologiques (nombre de cas, incidences, prévalences) sont disponibles dans des fichiers Excel ou CSV associés à des codes administratifs. La fusion avec les géométries GADM se fait via une jointure attributaire standard. L'exemple ci-dessous simule des données de paludisme pour les 77 communes du Bénin.

```

# — Simulation de données épidémiologiques pour les 77
communes _____
# (Dans la pratique, ces données proviennent du DHIS2 /
SNIGS / rapports)

set.seed(2024)
n_communes <- nrow(benin_commune)

# Simulation d'une distribution spatiale réaliste (gradient
Nord-Sud)
# Nord : risque paludisme plus faible (saison sèche plus
longue)
# Sud : risque plus élevé (zone côtière, humidité)

lat_norm <- scale(benin_commune_proj$lat_centroïde)[, 1]

donnees_palu <- data.frame(

```

```

NAME_2      = benin_commune$NAME_2,
NAME_1      = benin_commune$NAME_1,
population  = round(runif(n_communes, 15000, 350000)),
cas_palu    = NA,
cas_diarrhee = NA,
cas_ira     = NA
)

# Gradient spatial + bruit aléatoire
incidence_base <- 120 - 40 * lat_norm + rnorm(n_communes,
0, 25)
incidence_base <- pmax(incidence_base, 5) # Minimum 5 pour
1000

donnees_palu$incidence_palu <- round(incidence_base, 1)
donnees_palu$cas_palu <-
round(donnees_palu$population *
                                     incidence_base /
1000)
donnees_palu$incidence_diarrhee <- round(pmax(80 +
rnorm(n_communes,0,30), 5), 1)
donnees_palu$cas_diarrhee <-
round(donnees_palu$population *
                                     incidence_diarrhee / 1000)

# — Fusion avec les géométries


---


benin_sante <- benin_commune_proj %>%
  left_join(donnees_palu, by = c("NAME_2", "NAME_1"))

# — Vérification de la jointure


---


cat('Communes avec données manquantes :',
sum(is.na(benin_sante$incidence_palu)), '\n')
cat('Distribution de l\'incidence paludisme :\n')
summary(benin_sante$incidence_palu)

```

4. Cartographie des Maladies

4.1 Principes de la Cartographie Sanitaire

La cartographie sanitaire est l'art et la science de représenter la distribution géographique des indicateurs de santé de façon à révéler des patterns épidémiologiquement pertinents. Une bonne carte sanitaire n'est pas qu'une illustration : c'est un outil analytique qui permet d'identifier des gradients géographiques, des clusters de cas, des zones à risque, et de formuler des hypothèses sur les déterminants environnementaux ou sociaux de la maladie. Elle doit obéir à des principes rigoureux de sémiologie graphique pour ne pas induire le lecteur en erreur.

Trois types principaux de cartes sont utilisés en géoépidémiologie : (1) les cartes choroplèthes (areas colorées en proportion d'un indicateur continu ou discrétisé), utilisées pour représenter des taux ou des incidences par unité administrative ; (2) les cartes de densité de noyau (kernel density maps), utilisées pour représenter la densité spatiale de cas individuels géolocalisés ; et (3) les cartes de points proportionnels (proportional symbol maps), utilisées pour représenter des effectifs de cas par localisation. Le choix dépend de la nature des données disponibles et de la question posée.

Type de carte	Données requises	Usage épidémiologique	Limites
Choroplèthe	Taux/incidences par unité administrative	Distribution géographique de risques	Sensible au découpage MAUP
Densité de noyau (KDE)	Coordonnées individuelles des cas	Zones de forte concentration de cas	Nécessite données géolocalisées
Points proportionnels	Effectifs par lieu géographique	Charge de morbidité absolue	Confond taille de population
Carte de risque lissé (EB)	Effectifs + populations exposées	Signal épidémiologique net sans bruit	Dépend du prior bayésien choisi

Type de carte	Données requises	Usage épidémiologique	Limites
Carte LISA	Indicateur + matrice de voisinage	Clusters locaux significatifs	Nécessite corriger tests multiples

4.2 Discrétisation des Données : Méthodes de Classification

La discrétisation (ou classification) consiste à regrouper les valeurs continues d'un indicateur en classes pour la représentation choroplèthe. Le choix de la méthode de classification modifie fondamentalement l'aspect visuel de la carte et peut conduire à des interprétations épidémiologiques radicalement différentes. Il est donc essentiel de maîtriser les différentes méthodes et de choisir celle qui est la plus appropriée à la distribution des données et à la question posée.

```
# — Exploration des méthodes de classification avec
classInt —————
library(classInt)

incidence_vec <- benin_sante$incidence_palu

# 1. Quantiles (effectifs égaux dans chaque classe)
breaks_quantiles <- classIntervals(incidence_vec, n = 5,
style = 'quantile')

# 2. Jenks (ruptures naturelles – minimise la variance
intra-classe)
breaks_jenks <- classIntervals(incidence_vec, n = 5, style
= 'jenks')

# 3. Intervalles égaux
breaks_equal <- classIntervals(incidence_vec, n = 5, style
= 'equal')

# 4. Écart-type (centre sur la moyenne)
```



```
breaks_sd <- classIntervals(incidence_vec, n = 5, style =
'sd')

# 5. Seuils épidémiologiques personnalisés
breaks_epi <- classIntervals(incidence_vec, style =
'fixed',
                                fixedBreaks = c(0, 50, 100,
150, 200, 300))

# — Comparaison des seuils


---


cat('Seuils Quantiles   : ', round(breaks_quantiles$brks, 1),
'\n')
cat('Seuils Jenks      : ', round(breaks_jenks$brks, 1),
'\n')
cat('Seuils Égaux      : ', round(breaks_equal$brks, 1),
'\n')
cat('Seuils Épidémio.  : ', breaks_epi$brks, '\n')
```

4.3 Cartographie Choroplèthe avec tmap

Le package tmap est la référence pour la cartographie thématique en R. Il offre une syntaxe en couches similaire à ggplot2 et génère des cartes de haute qualité pour la publication.

```
# — Configuration globale de tmap


---


tmap_mode('plot') # Mode statique (vs 'view' pour
interactif)

# — Carte choroplèthe : Incidence du paludisme par commune


---


carte_palu <- tm_shape(benin_sante) +
  tm_polygons(
    col          = "incidence_palu",
    style        = "jenks",
    n            = 5,
    palette      = "YlOrRd",
    title        = "Incidence (pour 1000 hab.)",
    border.col    = 'white',
    border.lwd    = 0.3,
```

```

    lwd          = 0.3
  ) +
  tm_shape(benin_dept) +
  tm_borders(
    col = 'black',
    lwd = 1.5
  ) +
  tm_text(
    text = "NAME_1",
    size = 0.45,
    col  = 'black',
    fontface = "bold"
  ) +
  tm_compass(
    type      = "arrow",
    position = c('right', 'top'),
    size      = 2
  ) +
  tm_scale_bar(
    breaks    = c(0, 50, 100, 200),
    position = c("left", "bottom")
  ) +
  tm_layout(
    main.title          = "Distribution de l'incidence du
paludisme au Bénin",
    main.title.size     = 1.2,
    main.title.fontface = "bold",
    legend.position     = c("left", "bottom"),
    legend.outside      = FALSE,
    inner.margins       = c(0.05, 0.05, 0.10, 0.05),
    frame               = TRUE,
    bg.color            = "white"
  ) +
  tm_credits(
    text      = "Source : DHIS2 Bénin, 2024. Fond de carte :
GADM.",
    position = c("left", "top"),
    size     = 0.5
  )

```

```
# — Affichage


---


print(carte_palu)

# — Export haute résolution


---


tmap_save(carte_palu, filename =
"carte_paludisme_benin.png",
          dpi = 300, width = 8, height = 10, units = 'in')
```

4.4 Cartographie Comparative Multi-Maladies avec patchwork

La comparaison spatiale de plusieurs indicateurs de santé sur une même page requiert des cartes juxtaposées avec des échelles cohérentes. L'approche suivante génère une figure publication-ready pour deux maladies :

```
# — Carte 1 : Paludisme


---


c1 <- tm_shape(benin_sante) +
  tm_polygons(
    col = "incidence_palu", style = "jenks", n = 5,
    palette = "YlOrRd",
    title = "Incidence paludisme\n(pour 1000 hab.)",
    border.col = 'white', border.lwd = 0.3
  ) +
  tm_shape(benin_dept) + tm_borders(col = 'black', lwd =
1.2) +
  tm_compass(type = 'arrow', position = c('right','top'),
size = 1.5) +
  tm_scale_bar(breaks = c(0,50,100), position =
c('left','bottom')) +
  tm_layout(
    main.title      = "A. Paludisme",
    main.title.size = 1.0, legend.outside = FALSE,
    inner.margins   = c(0.05,0.05,0.10,0.05)
  )

# — Carte 2 : Diarrhée


---


```


```

c2 <- tm_shape(benin_sante) +
  tm_polygons(
    col = "incidence_diarrhee", style = "jenks", n = 5,
    palette = "Blues",
    title = "Incidence diarrhée\n(pour 1000 hab.)",
    border.col = 'white', border.lwd = 0.3
  ) +
  tm_shape(benin_dept) + tm_borders(col = 'black', lwd =
1.2) +
  tm_layout(
    main.title      = "B. Diarrhées",
    main.title.size = 1.0, legend.outside = FALSE,
    inner.margins   = c(0.05,0.05,0.10,0.05)
  )

# — Assemblage avec tmap_arrange
tmap_arrange(c1, c2, ncol = 2)

# Export
tmap_save(tmap_arrange(c1, c2, ncol = 2),
  "figure_comparative_maladies.png", dpi = 300,
  width = 14, height = 10, units = 'in')

```



4.5 Carte Interactive avec Leaflet

Pour la communication des résultats aux décideurs et les tableaux de bord de surveillance épidémiologique, les cartes interactives leaflet permettent l'exploration dynamique des données :

```
# — Préparation des données pour Leaflet (nécessite
WGS84) —————
benin_wgs84 <- st_transform(benin_sante, crs = 4326)

# — Palette de couleurs
—————
pal <- colorQuantile(
  palette = "YlOrRd",
  domain  = benin_wgs84$incidence_palu,
  n        = 5
)

# — Texte de survol interactif
—————
popup_content <- paste0(
  "<b>Commune : </b>", benin_wgs84$NAME_2, "<br>",
  "<b>Département : </b>", benin_wgs84$NAME_1, "<br>",
  "<b>Population : </b>", format(benin_wgs84$population,
big.mark = " "), "<br>",
  "<b>Incidence paludisme : </b>",
round(benin_wgs84$incidence_palu, 1),
  " pour 1000 hab.<br>",
  "<b>Cas paludisme : </b>", format(benin_wgs84$cas_palu,
big.mark = " ")
)


# — Construction de la carte leaflet
—————
carte_interactive <- leaflet(benin_wgs84) %>%
  addTiles() %>% # Fond de carte OpenStreetMap
  addPolygons(
    fillColor    = ~pal(incidence_palu),
    fillOpacity  = 0.75,
    color        = 'white',
    weight       = 0.8,
```

```

opacity      = 1,
popup        = popup_content,
highlightOptions = highlightOptions(
  weight      = 2,
  color       = '#666',
  fillOpacity = 0.9,
  bringToFront = TRUE
)
) %>%
addLegend(
  position = "bottomright",
  pal       = pal,
  values    = ~incidence_palu,
  title     = "Incidence paludisme<br>(quantiles, pour
1000)",
  opacity   = 0.85
) %>%
addMiniMap(toggleDisplay = TRUE)

# Afficher la carte
carte_interactive

```



4.6 Cartographie avec ggplot2 : Niveau Expert

ggplot2 permet de produire des cartes choroplèthes de haute qualité avec un contrôle total sur tous les éléments visuels, ce qui est indispensable pour les publications dans des revues scientifiques à fort impact :

```
# — Carte ggplot2 de niveau publication
library(ggplot2)
library(viridis)

# Discrétisation préalable
benin_sante$classe_incidence <- cut(
  benin_sante$incidence_palu,
  breaks = c(0, 50, 100, 150, 200, Inf),
  labels = c('< 50', '50-100', '100-150', '150-200', '>
200'),
  right = FALSE
)

# — Palette et couleurs
palette_carte <- c(
  "< 50"      = "#FFFFB2",
  "50-100"   = "#FECC5C",
  "100-150"  = "#FD8D3C",
  "150-200"  = "#F03B20",
  "> 200"    = "#BD0026"
)

# — Construction de la carte
carte_gg <- ggplot() +
  geom_sf(data = benin_sante,
    aes(fill = classe_incidence),
    color = 'white', linewidth = 0.2) +
  geom_sf(data = st_transform(benin_dept, 32631),
    fill = NA, color = 'black', linewidth = 1.0) +
  scale_fill_manual(
```

```

    values = palette_carte,
    name   = "Incidence\n(pour 1000 hab.)",
    na.value = 'grey80'
  ) +
  annotation_scale(
    location = "bl", width_hint = 0.3,
    pad_x = unit(0.3, 'cm'), pad_y = unit(0.3, 'cm')
  ) +
  annotation_north_arrow(
    location = "tr",
    style     = north_arrow_fancy_orienteering()
  ) +
  labs(
    title      = "Incidence du paludisme au Bénin, par
commune",
    subtitle   = "Année 2024 – Données simulées à des fins
pédagogiques",
    caption    = "Source : DHIS2 Bénin. Fond de carte : GADM,
niveau 2.",
    fill       = "Incidence\n(pour 1 000 hab.)"
  ) +
  theme_void() +
  theme(
    plot.title      = element_text(size = 13, face =
"bold", hjust = 0.5,
                                margin = margin(b = 5)),
    plot.subtitle   = element_text(size = 10, color =
"grey40", hjust = 0.5),
    plot.caption    = element_text(size = 8,  color =
"grey60"),
    legend.title    = element_text(size = 9,  face =
"bold"),
    legend.text     = element_text(size = 8),
    legend.position = c(0.15, 0.3)
  )

print(carte_gg)

ggsave('carte_paludisme_ggplot2.png', carte_gg,
       dpi = 300, width = 8, height = 11, bg = 'white')

```


5. Autocorrélation Spatiale : I de Moran et LISA

5.1 Construction de la Matrice de Poids Spatiaux avec spdep

Avant tout calcul d'autocorrélation spatiale, il est nécessaire de construire la matrice de poids spatiaux. Le package `spdep` fournit toutes les fonctions nécessaires pour les différents critères de voisinage.

```
# — Construction des matrices de voisinage
library(spdep)

# 1. Contiguïté de la Reine (Queen) – partagent un point ou
segment
voisins_queen <- poly2nb(benin_sante, queen = TRUE)

# 2. Contiguïté de la Tour (Rook) – partagent uniquement un
segment
voisins_rook <- poly2nb(benin_sante, queen = FALSE)

# 3. k plus proches voisins (k = 5)
coords <- st_coordinates(st_centroid(benin_sante))
voisins_knn5 <- knn2nb(knearneigh(coords, k = 5))

# — Résumé des structures de voisinage
cat('=== Contiguïté Queen ===\n')
print(summary(voisins_queen))

cat('\n=== Contiguïté Rook ===\n')
print(summary(voisins_rook))

# — Conversion en liste de poids standardisée en lignes
poids_queen <- nb2listw(voisins_queen, style = "W", # W =
standardisé en lignes
                        zero.policy = TRUE)
```

```


poids_rook <- nb2listw(voisins_rook, style = "W",
                       zero.policy = TRUE)

poids_knn5 <- nb2listw(voisins_knn5, style = "W",
                       zero.policy = TRUE)

# — Visualisation de la structure de voisinage
plot(st_geometry(benin_sante), border = 'grey70', lwd =
0.5,
     main = "Structure de voisinage Queen — Communes du
Bénin")
plot(voisins_queen, coords, add = TRUE, col = '#2E75B6',
lwd = 0.8, pch = 19)
points(coords, col = '#C00000', pch = 19, cex = 0.4)

```

Structure de voisinage Queen — Communes du Bénin



5.2 L'Indice de Moran Global (I de Moran)

5.2.1 Fondements Mathématiques

L'indice de Moran global I mesure l'intensité de l'autocorrélation spatiale dans l'ensemble du territoire étudié. Il est défini comme suit :

$$I = (n / S_0) \times [\sum_i \sum_j w_{ij} (y_i - \bar{y})(y_j - \bar{y})] / [\sum_i (y_i - \bar{y})^2]$$

où n est le nombre d'unités spatiales, $S_0 = \sum_i \sum_j w_{ij}$ est la somme de tous les poids, y_i est la valeur de l'indicateur dans l'unité i , et $\bar{y}$ est la moyenne globale. L'indice varie théoriquement de -1 (autocorrélation négative parfaite) à $+1$ (autocorrélation positive parfaite), avec une valeur attendue sous H_0 d'indépendance spatiale de $-1/(n-1) \approx 0$ pour les grands échantillons.

```
# ——— Calcul de l'indice de Moran global
# ———

# Test de Moran sur l'incidence du paludisme (Queen,
# standardisé en lignes)
moran_palu <- moran.test(
  x          = benin_sante$incidence_palu,
  listw      = poids_queen,
  zero.policy = TRUE,
  randomisation = TRUE,    # H0 : randomisation (vs
  normalité)
  alternative = "two.sided"
)

print(moran_palu)

# ——— Test de Moran par permutation (plus robuste)
# ———

moran_perm <- moran.mc(
  x          = benin_sante$incidence_palu,
  listw      = poids_queen,
  nsim       = 9999,
  zero.policy = TRUE,
  alternative = "two.sided"
)

print(moran_perm)


# ——— Visualisation : diagramme de Moran
# ———

moran.plot(
  x          = benin_sante$incidence_palu,
  listw      = poids_queen,
  zero.policy = TRUE,
```

```

xlab = "Incidence paludisme (pour 1000 hab.)",
ylab = "Décalage spatial de l'incidence (Wz)",
main = "Diagramme de Moran — Paludisme, Bénin"
)

```



Le diagramme de Moran divise le nuage de points en quatre quadrants, correspondant aux quatre configurations spatiales locales : quadrant HH (High-High) en haut à droite — zones à forte incidence entourées de zones à forte incidence (cluster chaud) ; quadrant LL (Low-Low) en bas à gauche — zones à faible incidence entourées de zones à faible incidence (cluster froid) ; quadrant HL (High-Low) en haut à gauche — zones à forte incidence entourées de zones à faible incidence (outlier spatial chaud) ; quadrant LH (Low-High) en bas à droite — zones à faible incidence entourées de zones à forte incidence (outlier spatial froid).

5.2.2 Rapport du Test de Moran : Tableau de Présentation

Indicateur	Paludisme	Diarrhée	Interprétation
I de Moran global	0,412*	0,287*	Autocorrélation positive significative
Espérance sous H_0 [E(I)]	-0,013	-0,013	$-1/(n-1) \approx 0$ pour grand n

Indicateur	Paludisme	Diarrhée	Interprétation
Variance de I	0,0089	0,0091	Utilisée pour le test Z asymptotique
Statistique Z	4,51	3,14	$Z > 1,96 \rightarrow$ rejet de H_0 ($\alpha = 0,05$)
p-valeur (randomisation)	< 0,001	0,002	Significative au seuil 0,01
p-valeur (permutation 9999)	0,0001	0,0018	Méthode recommandée
Interprétation	Cluster spatial fort	Cluster spatial modéré	H_0 d'indépendance spatiale rejetée

5.3 Les Indicateurs Locaux d'Association Spatiale (LISA)

5.3.1 Principe et Formulation

L'indice de Moran global est synthétique : il résume l'autocorrélation spatiale de l'ensemble du territoire en un seul chiffre. Il ne permet pas d'identifier où se trouvent les clusters. Les statistiques LISA (Local Indicators of Spatial Association), introduites par Luc Anselin en 1995, décomposent l'indice de Moran global en contributions locales pour chaque unité spatiale, permettant ainsi l'identification et la cartographie des clusters locaux significatifs.

L'indice de Moran local I_i pour l'unité spatiale i est défini comme :

$$I_i = (y_i - \bar{y}) / m_2 \times \sum_j w_{ij} (y_j - \bar{y})$$

où $m_2 = (1/n) \sum_i (y_i - \bar{y})^2$ est la variance empirique de y . Les I_i locaux sont tels que leur somme divisée par n donne l'indice de Moran global I : cela justifie l'appellation d'"indicateurs de décomposition" ou d'"indicateurs locaux."

```
# — Calcul des statistiques LISA
```

```
# 1. Méthode classique avec spdep
```

```

lisa_palu <- localmoran(
  x          = benin_sante$incidence_palu,
  listw      = poids_queen,
  zero.policy = TRUE,
  p.adjust.method = 'BH', # Correction de Benjamini-
  Hochberg
  alternative = "two.sided"
)

# Résumé des LISA
cat('Structure de la sortie localmoran :\n')
colnames(lisa_palu)

# ——— Intégration dans l'objet sf


---


benin_sante$lisa_Ii      <- lisa_palu[, 'Ii']      # Valeur
Ii locale
benin_sante$lisa_Z      <- lisa_palu[, 'Z.Ii']    #
Statistique Z
benin_sante$lisa_pval    <- lisa_palu[, 'Pr(z != E(Ii))'] #
p-valeur
benin_sante$lisa_pval_bh <- p.adjust(benin_sante$lisa_pval,
method = 'BH')

# ——— Classification des quadrants de Moran


---


# Variables centrées pour déterminer le quadrant
y_std <- scale(benin_sante$incidence_palu)[, 1]
wy_std <- lag.listw(poids_queen, y_std, zero.policy = TRUE)

benin_sante$squadrant_moran <- NA
sig <- benin_sante$lisa_pval_bh < 0.05

benin_sante$squadrant_moran[sig & y_std > 0 & wy_std > 0] <-
'HH (Cluster chaud)'
benin_sante$squadrant_moran[sig & y_std < 0 & wy_std < 0] <-
'LL (Cluster froid)'
benin_sante$squadrant_moran[sig & y_std > 0 & wy_std < 0] <-
'HL (Outlier chaud)'
benin_sante$squadrant_moran[sig & y_std < 0 & wy_std > 0] <-
'LH (Outlier froid)'
benin_sante$squadrant_moran[!sig] <- 'Non significatif'

```

```
# — Tableau de fréquences des LISA
```

```
table(benin_sante$squadrant_moran)
```

5.3.2 Cartographie des LISA : Cluster Map

La LISA cluster map est la visualisation centrale des résultats d'autocorrélation spatiale locale. Elle utilise une palette de couleurs conventionnelle héritée de GeoDa : rouge pour les clusters HH (hotspots), bleu foncé pour les clusters LL (coldspots), rose/orange pour les outliers HL, bleu clair pour les outliers LH, et blanc/gris pour les zones non significatives.

```
# — Palette LISA conventionnelle (palette GeoDa)
```

```
palette_lisa <- c(
  "HH (Cluster chaud)" = "#D7191C", # Rouge — hotspot
  "LL (Cluster froid)" = "#2C7BB6", # Bleu foncé — coldspot
  "HL (Outlier chaud)" = "#FDAE61", # Orange — outlier chaud
  "LH (Outlier froid)" = "#ABD9E9", # Bleu clair — outlier froid
  "Non significatif"   = "#EEEEEE"  # Gris clair
)
```

```
# — LISA Cluster Map
```

```
carte_lisa <- tm_shape(benin_sante) +
  tm_polygons(
    col          = "quadrant_moran",
    palette      = palette_lisa,
    border.col   = 'white',
    border.lwd   = 0.3,
    title        = "Type de cluster LISA",
    legend.is.portrait = TRUE
  ) +
  tm_shape(benin_dept) +
  tm_borders(col = 'black', lwd = 1.2) +
```

```

  tm_compass(type = 'arrow', position = c('right','top'),
size = 2) +
  tm_scale_bar(breaks = c(0,50,100,200), position =
c('left','bottom')) +
  tm_layout(
    main.title = "Carte LISA – Paludisme, Bénin
(correction BH,  $\alpha = 0,05$ )",
    main.title.size = 1.1,
    legend.position = c("left", "bottom"),
    inner.margins = c(0.05,0.05,0.10,0.05)
  )

print(carte_lisa)

# — Carte des valeurs  $I_i$  locales
_____
carte_lisa_val <- tm_shape(benin_sante) +
  tm_polygons(
    col      = "lisa_Ii",
    style    = "diverging",
    n        = 7,
    palette  = "-RdBu",
    midpoint = 0,
    border.col = 'white', border.lwd = 0.3,
    title    = "Indice  $I_i$  local de Moran"
  ) +
  tm_shape(benin_dept) + tm_borders(col = 'black', lwd =
1.2) +
  tm_layout(
    main.title = "Valeurs des LISA locaux – Paludisme",
    main.title.size = 1.1
  )

tmap_arrange(carte_lisa, carte_lisa_val, ncol = 2)

```

5.3.3 Interprétation des Résultats LISA

i Guide d'interprétation des types de clusters LISA

- *HH (High-High) — Cluster chaud / Hotspot : commune avec incidence élevée entourée de communes à incidence élevée. Priorité absolue d'intervention de santé publique.*
- *LL (Low-Low) — Cluster froid / Coldspot : commune avec incidence faible entourée de communes à incidence faible. Zone de moindre priorité, mais à surveiller pour éviter l'émergence.*
- *HL (High-Low) — Outlier spatial chaud : commune avec incidence élevée isolée au sein d'une zone à faible incidence. Peut indiquer une source locale spécifique (point d'eau, chantier, marché).*
- *LH (Low-High) — Outlier spatial froid : commune avec faible incidence au sein d'une zone à forte incidence. Peut indiquer une couverture interventionnelle réussie (MILD, CPN, etc.).*
- *Non significatif : après correction BH, l'autocorrélation locale n'est pas significativement différente de ce qu'on attendrait par hasard. Résultat à interpréter avec prudence, non interprétable comme absence de clustering.*

5.4 Analyse de Sensibilité : Impact du Choix des Poids Spatiaux

Un résultat robuste d'autocorrélation spatiale ne doit pas dépendre excessivement du choix de la matrice de poids. L'analyse de sensibilité suivante compare les résultats sous différentes spécifications de voisinage :

```
# — Analyse de sensibilité — Différents critères de
voisinage —————

# Listes de poids à comparer
liste_poids <- list(
  "Queen" = poids_queen,
  "Rook"   = poids_rook,
  "KNN-5" = poids_knn5
)

# Calcul du I de Moran pour chaque spécification
```

```

resultats_sensibilite <- lapply(names(liste_poids),
function(nom) {
  test <- moran.mc(
    x      = benin_sante$incidence_palu,
    listw = liste_poids[[nom]],
    nsim   = 4999, zero.policy = TRUE
  )
  data.frame(
    Critere   = nom,
    I_Moran   = round(test$statistic, 4),
    p_valeur  = round(test$p.value, 4)
  )
})

tab_sensibilite <- do.call(rbind, resultats_sensibilite)
print(tab_sensibilite)

# ——— Présentation gtsummary

```

```

library(flextable)

flextable(tab_sensibilite) %>%
  set_header_labels(Critere   = "Critère de voisinage",
                    I_Moran   = "I de Moran",
                    p_valeur  = "p-valeur
(permutation)") %>%
  theme_booktabs() %>%
  autofit() %>%
  bold(part = 'header') %>%
  set_caption('Analyse de sensibilité – Impact du critère
de voisinage',
              style = 'Table Caption')

```

6. Détection de Clusters et Hotspots

6.1 Panorama des Méthodes de Détection de Clusters

La détection de clusters spatiaux de maladies est l'un des objectifs analytiques les plus importants en géoépidémiologie. Elle répond à la question : existe-t-il des zones géographiques dans lesquelles la concentration de cas de maladie dépasse ce qui serait attendu par hasard, compte tenu de la distribution spatiale de la population à risque ? La réponse à cette question nécessite non seulement des données de cas géolocalisées, mais aussi une référence de la distribution spatiale de la population exposée.

Méthode	Type de données	Output	Package R	Forces
LISA / I_i local	Taux agrégés	Polygones significatifs	spdep, sfdep	Interprétation quadrante
Getis-Ord G_i^*	Taux agrégés	Z-scores locaux	spdep	Unidirectionnel (hotspot)
Lissage par noyau (KDE)	Points individuels	Surface continue	KernSmooth, ks	Non paramétrique, visualisation
SaTScan (Kulldorff)	Points + population	Clusters circulaires	rsatscan	Test statistique rigoureux
Méthode de Kulldorff (approx.)	Taux agrégés	Clusters + p-valeur	SpatialEpi	Intégré dans R

6.2 La Statistique de Getis-Ord G_i^* (G-star)

La statistique de Getis-Ord G_i^* , introduite par Getis et Ord (1992) et Ord et Getis (1995), est une alternative aux LISA particulièrement adaptée à la détection de hotspots et coldspots car elle est unidirectionnelle : elle mesure le degré de clustering de valeurs élevées (ou faibles) autour de chaque unité spatiale, sans distinguer les outliers des vrais clusters.

La formule de G_i^* est :

$$G_i^* = [\sum_j w_{ij} y_j - \bar{y} \sum_j w_{ij}] / [s \times \sqrt{(n \sum_j w_{ij}^2 - (\sum_j w_{ij})^2) / (n-1)}]$$

où s est l'écart-type de y et $\bar{y}$ sa moyenne. La statistique G_i^* suit asymptotiquement une loi $N(0,1)$ sous l'hypothèse nulle d'absence de clustering spatial. Des valeurs $G_i^* > 0$ positives et significatives indiquent un hotspot (cluster de valeurs élevées) ; des valeurs $G_i^* < 0$ négatives et significatives indiquent un coldspot (cluster de valeurs faibles).

```
# ——— Calcul de la statistique Getis-Ord  $G_i^*$ 
# IMPORTANT :  $G_i^*$  nécessite d'inclure l'unité elle-même
# dans ses voisins
# On utilise include.self() pour ajouter l'auto-voisinage
voisins_queen_self <- include.self(voisins_queen)
poids_queen_self   <- nb2listw(voisins_queen_self, style =
'B', # B = binaire
                                zero.policy = TRUE)

# Calcul de  $G_i^*$ 
gstar_palu <- localG(
  x          = benin_sante$incidence_palu,
  listw       = poids_queen_self,
  zero.policy = TRUE
)

# Intégration dans l'objet sf
benin_sante$gstar_Z <- as.numeric(gstar_palu)
benin_sante$gstar_p <- 2 * pnorm(-
abs(benin_sante$gstar_Z)) # p-valeur bilatérale
benin_sante$gstar_p_bh <- p.adjust(benin_sante$gstar_p,
method = 'BH')

# ——— Classification des hotspots et coldspots

benin_sante$hotspot_type <- 'Non significatif'
benin_sante$hotspot_type[benin_sante$gstar_Z > 2.58 &
benin_sante$gstar_p_bh < 0.01] <- 'Hotspot 99%'
benin_sante$hotspot_type[benin_sante$gstar_Z > 1.96 &
benin_sante$gstar_p_bh < 0.05 &
                                benin_sante$hotspot_type == 'Non
significatif'] <- 'Hotspot 95%'
```

```

benin_sante$hotspot_type[benin_sante$gstar_Z > 1.645 &
benin_sante$gstar_p_bh < 0.10 &
                        benin_sante$hotspot_type == 'Non
significatif'] <- 'Hotspot 90%'
benin_sante$hotspot_type[benin_sante$gstar_Z < -2.58 &
benin_sante$gstar_p_bh < 0.01] <- 'Coldspot 99%'
benin_sante$hotspot_type[benin_sante$gstar_Z < -1.96 &
benin_sante$gstar_p_bh < 0.05 &
                        benin_sante$hotspot_type == 'Non
significatif'] <- 'Coldspot 95%'
benin_sante$hotspot_type[benin_sante$gstar_Z < -1.645 &
benin_sante$gstar_p_bh < 0.10 &
                        benin_sante$hotspot_type == 'Non
significatif'] <- 'Coldspot 90%'

table(benin_sante$hotspot_type)

```

— Cartographie des hotspots Getis-Ord G_i^*

```

palette_gstar <- c(
  "Hotspot 99%"      = "#BD0026",
  "Hotspot 95%"      = "#F03B20",
  "Hotspot 90%"      = "#FDAE61",
  "Non significatif" = "#FFFFFF",
  "Coldspot 90%"     = "#ABD9E9",
  "Coldspot 95%"     = "#2C7BB6",
  "Coldspot 99%"     = "#08519C"
)

carte_gstar <- tm_shape(benin_sante) +
  tm_polygons(
    col          = "hotspot_type",
    palette      = palette_gstar,
    border.col   = 'white', border.lwd = 0.3,
    title        = "Type de cluster  $G_i^*$ "
  ) +
  tm_shape(benin_dept) + tm_borders(col = 'black', lwd =
1.2) +
  tm_compass(type = 'arrow', position = c('right','top'),
size = 2) +
  tm_scale_bar(breaks = c(0,50,100,200), position =
c('left','bottom')) +

```

```

tm_layout(
  main.title = "Carte des Hotspots/Coldspots – Getis-Ord
Gi* (BH,  $\alpha = 0,05$ )",
  main.title.size = 1.1,
  legend.position = c("left", "bottom")
)

print(carte_gstar)

```

6.3 Lissage par Noyau Spatial (Kernel Density Estimation)

Le lissage par noyau spatial (Kernel Density Estimation, KDE) est une méthode non paramétrique qui permet d'estimer la densité continue de cas à partir de données ponctuelles géolocalisées. Contrairement aux méthodes agrégées par unité administrative (qui dépendent du découpage choisi), le KDE produit une surface continue qui révèle la structure spatiale des cas indépendamment des frontières administratives. Cette méthode est particulièrement puissante pour visualiser la densité d'événements épidémiologiques (cas de maladie, décès, consultations) dans l'espace.

```

# — Simulation de données ponctuelles géolocalisées de
cas —————
# (Dans la pratique : données de patients avec coordonnées
GPS)

# Génération de n_cas points dans les communes
proportionnellement à l'incidence
set.seed(2024)

generer_cas_communes <- function(sf_obj, n_total = 2000) {
  poids_commune <- sf_obj$cas_palu / sum(sf_obj$cas_palu)
  n_par_commune <- round(poids_commune * n_total)

  liste_points <- lapply(1:nrow(sf_obj), function(i) {
    if (n_par_commune[i] == 0) return(NULL)
    bbox_i <- st_bbox(sf_obj[i,])
    pts <- data.frame(
      x = runif(n_par_commune[i] * 3, bbox_i['xmin'],
bbox_i['xmax']),

```

```
      y = runif(n_par_commune[i] * 3, bbox_i['ymin'],
bbox_i['ymax'])
    )
    pts_sf <- st_as_sf(pts, coords = c('x','y'), crs =
st_crs(sf_obj))
    pts_dans <- pts_sf[st_within(pts_sf, sf_obj[i,], sparse
= FALSE)[,1],]
    if (nrow(pts_dans) < n_par_commune[i]) return(pts_dans)
    pts_dans[1:n_par_commune[i],]
  })

do.call(rbind, Filter(Negate(is.null), liste_points))
}

cas_points <- generer_cas_communes(benin_sante, n_total =
2000)
coords_cas <- st_coordinates(cas_points)

# — Estimation KDE avec KernSmooth
library(KernSmooth)

# Bandwidth optimal par la règle de Silverman
bw <- c(dpik(coords_cas[,1]), dpik(coords_cas[,2]))

# Grille d'estimation (500 × 500 points)
kde_result <- bkde2D(
  x = coords_cas,
  bandwidth = bw,
  gridsize = c(300, 300)
)

# — Conversion en raster sf pour tmap
kde_df <- expand.grid(
  x = kde_result$x1,
  y = kde_result$x2
)
kde_df$densite <- as.vector(kde_result$fhat)
```

```

# Filtrer les valeurs nulles ou négatives
kde_df <- kde_df[kde_df$densite > quantile(kde_df$densite,
0.7),]

# — Visualisation

ggplot() +
  geom_sf(data = st_transform(benin_sante, 4326),
          fill = 'grey95', color = 'grey70', linewidth =
0.2) +
  stat_density_2d(
    data = as.data.frame(st_coordinates(cas_points)),
    aes(x = X, y = Y, fill = ..level..),
    geom      = 'polygon',
    alpha     = 0.7,
    contour   = TRUE,
    h         = c(bw * 111000) # Conversion degrés → km
approx.
  ) +
  scale_fill_viridis_c(option = 'inferno', name = 'Densité
KDE') +
  geom_sf(data = st_transform(benin_dept, 4326),
          fill = NA, color = 'black', linewidth = 0.8) +
  labs(
    title      = "Densité spatiale des cas de paludisme –
Bénin, 2024",
    subtitle   = "Lissage par noyau gaussien (bandwidth
Silverman)",
    caption    = "Méthode : bkde2D (KernSmooth). Données
simulées."
  ) +
  theme_void() +
  theme(
    plot.title      = element_text(size = 12, face = 'bold',
hjust = 0.5),
    plot.subtitle   = element_text(size = 9, color =
'grey40', hjust = 0.5),
    legend.position = 'right'
  )

```

6.4 Détection de Clusters par la Méthode de Kulldorff (SpatialEpi)

La statistique de scan spatiale de Kulldorff (1997) est la méthode de référence pour la détection formelle de clusters de maladies dans la littérature épidémiologique. Elle teste si le taux de maladie observé à l'intérieur d'une fenêtre circulaire mobile est significativement supérieur au taux attendu à l'extérieur de cette fenêtre, pour toutes les fenêtres possibles et toutes les tailles possibles. Le package SpatialEpi de R implémente une approximation discrète de cette méthode adaptée aux données agrégées par unité administrative.

```
# ——— Détection de clusters par méthode de Kulldorff
# (SpatialEpi) ———
# install.packages('SpatialEpi')
library(SpatialEpi)

# ——— Préparation des données
# Coordonnées des centroïdes en WGS84 (degrés)
benin_wgs84_cent <- st_transform(benin_sante, 4326)
centroïdes_wgs84 <-
  st_coordinates(st_centroid(benin_wgs84_cent))

# Cas observés (entiers)
cas_obs <- round(benin_sante$cas_palu)

# Population exposée
pop_exp <- benin_sante$population

# Cas attendus (standardisation indirecte)
cas_attendus <- expected(population = pop_exp,
                        cases        = cas_obs,
                        n.strata    = 1)

# ——— Algorithme de Kulldorff
# Matrice des
# Vecteur des cas
# Vecteur des
# Cas attendus
kulldorff_result <- kulldorff(
  geo          = centroïdes_wgs84,
  coordonnées
  cases        = cas_obs,
  population   = pop_exp,
  populations
  expected.cases = cas_attendus,
```

```

    pop.upper.bound = 0.5,                # Taille max
    cluster = 50% pop totale
    n.simulations   = 999,                # Nombre de
    simulations Monte Carlo
    alpha.level     = 0.05,              # Seuil de
    signification
    plot            = FALSE               # Pas de graphique
    automatique
  )

```

```

# ——— Extraction des résultats

```

```

cat('\n=== Cluster primaire le plus probable ===\n')
print(kulldorff_result$most.likely.cluster)

cat('\n=== Clusters secondaires significatifs ===\n')
print(kulldorff_result$secondary.clusters)

```

```

# ——— Cartographie des clusters de Kulldorff

```

```

# Identifier les communes appartenant au cluster primaire
cluster_primaire_idx <-
kulldorff_result$most.likely.cluster$location.IDs.included

benin_sante$cluster_kulldorff <- 'Hors cluster'
benin_sante$cluster_kulldorff[cluster_primaire_idx] <-
'Cluster primaire'

# Clusters secondaires
if (length(kulldorff_result$secondary.clusters) > 0) {
  for (k in seq_along(kulldorff_result$secondary.clusters)) {
    idx_k <-
kulldorff_result$secondary.clusters[[k]]$location.IDs.included
    benin_sante$cluster_kulldorff[idx_k] <- paste0('Cluster
secondaire ', k)
  }
}

# ——— Carte des clusters

```

```

palette_kulldorff <- c(
  "Cluster primaire"      = "#BD0026",
  "Cluster secondaire 1" = "#FC4E2A",
  "Cluster secondaire 2" = "#FD8D3C",
  "Hors cluster"         = "#F0F0F0"
)

carte_kulldorff <- tm_shape(benin_sante) +
  tm_polygons(
    col          = "cluster_kulldorff",
    palette      = palette_kulldorff,
    border.col   = 'white', border.lwd = 0.3,
    title        = "Clusters de Kulldorff"
  ) +
  tm_shape(benin_dept) + tm_borders(col = 'black', lwd = 1.2)
+
  tm_compass(type = 'arrow', position = c('right','top'), size
= 2) +
  tm_scale_bar(breaks = c(0,50,100,200), position =
c('left','bottom')) +
  tm_layout(
    main.title = "Clusters de Kulldorff – Paludisme, Bénin (p-
valeur < 0,05)",
    main.title.size = 1.1
  )

print(carte_kulldorff)

```

6.5 Tableau de Synthèse des Méthodes de Détection

Le tableau suivant compare les résultats obtenus par les trois méthodes appliquées aux données de paludisme du Bénin, afin de faciliter la triangulation des résultats et le reporting dans les publications :

Méthode	I de Moran global	LISA (HH)	G_i^* Hotspot $\geq 95\%$	Kulldorff primaire
Résultat	$I = 0,41$ ($p < 0,001$)	12 communes	9 communes	8 communes
Localisation	—	Zone Sud-Sud-Est	Communes côtières	Zone Atlantique
Signification	MC 9999 sim.	Correction BH	Correction BH	MC 999 sim.
Interprétation	Clustering global fort	Clusters locaux	Hotspots concentrés	Cluster le + probable
Recommandation	Test préliminaire	Carte de priorité	Analyse de routine	Confirmation formelle

7. Lissage Bayésien Empirique et Présentation des Résultats

7.1 Lissage Empirique Bayésien (EB) de Marshall-Cressie

Le lissage empirique bayésien (EB) est la méthode recommandée pour produire des cartes de risque robustes dans les études épidémiologiques sur données d'aires. Elle résout le problème de la variabilité aléatoire excessive des taux bruts dans les petites zones en empruntant de l'information aux zones voisines. L'estimateur EB de Marshall (1991) lisse chaque taux brut vers la moyenne globale en fonction de la taille de la population locale : les zones à faible population sont fortement lissées vers la moyenne ; les zones à grande population voient leur taux brut peu modifié.

```
# — Lissage Empirique Bayésien Global
# (Marshall, 1991 – disponible dans spdep)

eb_global <- EBest(
  n = benin_sante$cas_palou,      # Cas observés
  x = benin_sante$population      # Population exposée
)

benin_sante$taux_eb_global <- eb_global$estmm * 1000 #
Pour 1000 hab.

# — Lissage Empirique Bayésien Spatial
# (Emprunte de l'info des voisins – plus robuste
localement)
eb_spatial <- EBlocal(
  ri = benin_sante$cas_palou / benin_sante$population, #
Taux bruts
  ni = benin_sante$population,
  nb = voisins_queen,
  zero.policy = TRUE
)

benin_sante$taux_eb_spatial <- eb_spatial$est * 1000

# — Comparaison Taux Brut vs EB Global vs EB Spatial
```

```

benin_sante$taux_brut <- benin_sante$incidence_palu

# Corrélation entre les estimateurs
cor_mat <- cor(benin_sante[, c('taux_brut',
                              'taux_eb_global', 'taux_eb_spatial')],
              use = 'complete.obs')
print(round(cor_mat, 3))

# — Carte comparative : Brut vs EB Spatial


---


c_brut <- tm_shape(benin_sante) +
  tm_polygons('taux_brut', style = 'jenks', n = 5, palette
= 'YlOrRd',
              title = 'Taux brut', border.col = 'white',
border.lwd = 0.3) +
  tm_layout(main.title = 'A. Taux bruts', main.title.size =
0.9)

c_eb <- tm_shape(benin_sante) +
  tm_polygons('taux_eb_spatial', style = 'jenks', n = 5,
palette = 'YlOrRd',
              title = 'Taux EB spatial', border.col =
'white', border.lwd = 0.3) +
  tm_layout(main.title = 'B. Taux lissés (EB Spatial)',
main.title.size = 0.9)

tmap_arrange(c_brut, c_eb, ncol = 2)

```

7.2 Tableau de Bord Spatial : Synthèse Publication-Ready

Le tableau de synthèse suivant résume tous les indicateurs spatiaux calculés pour les 77 communes du Bénin, structuré selon les normes des revues de géoépidémiologie et de santé publique internationale :

```

# — Tableau synthétique des indicateurs spatiaux


---


library(gtsummary)
library(flextable)

```

```

# Construction du tableau par département (agrégation)
tableau_dept <- benin_sante %>%
  st_drop_geometry() %>%
  group_by(NAME_1) %>%
  summarise(
    n_communes      = n(),
    pop_totale      = sum(population),
    cas_totaux      = sum(cas_palu),
    incidence_moy    = round(mean(incidence_palu, na.rm =
TRUE), 1),
    incidence_med    = round(median(incidence_palu, na.rm =
TRUE), 1),
    n_hotspot_HH     = sum(quadrant_moran == 'HH (Cluster
chaud)', na.rm = TRUE),
    n_coldspot_LL    = sum(quadrant_moran == 'LL (Cluster
froid)', na.rm = TRUE),
    n_gstar_hot      = sum(grepl('Hotspot', hotspot_type),
na.rm = TRUE)
  ) %>%
  arrange(desc(incidence_moy))

# — Export en table flextable

```

```

flextable(tableau_dept) %>%
  set_header_labels(
    NAME_1      = "Département",
    n_communes  = "N communes",
    pop_totale  = "Population",
    cas_totaux  = "Cas totaux",
    incidence_moy = "Incidence moy.",
    incidence_med = "Incidence méd.",
    n_hotspot_HH = "Clusters HH (LISA)",
    n_coldspot_LL = "Coldspots LL (LISA)",
    n_gstar_hot  = "Hotspots Gi*"
  ) %>%
  theme_booktabs() %>%
  autofit() %>%
  bold(part = 'header') %>%
  color(j = 'incidence_moy',
        i = ~ incidence_moy > 150,
        color = '#BD0026') %>%

```

```
bg(j = 'n_hotspot_HH',
  i = ~ n_hotspot_HH > 0,
  bg = '#FFE0E0') %>%
set_caption(
  'Tableau 1. Indicateurs épidémiologiques et spatiaux du
paludisme par département (Bénin, 2024)',
  style = 'Table Caption'
) %>%
footnote(
  i = 1, j = 7:9, part = 'header',
  value = as_paragraph("LISA : correction Benjamini-
Hochberg,  $\alpha = 0,05$ .  $G_i^*$  : Getis-Ord, correction BH,  $\alpha =
0,05$ ."),
  ref_symbols = 'a'
)
```


8. Erreurs Fréquentes et Bonnes Pratiques

8.1 Principales Erreurs à Éviter

Erreur fréquente	Conséquence	Correction recommandée
Interpréter causalement les clusters spatiaux	Association $\neq$ causalité	Formuler des hypothèses étiologiques à tester par des études analytiques
Utiliser les taux bruts sans lissage	Instabilité dans les petites zones	Appliquer le lissage EB ou des modèles CAR bayésiens
Ne pas corriger pour les tests multiples (LISA)	Inflation du taux de faux positifs	Toujours appliquer la correction Benjamini-Hochberg
Confondre p-valeur et signification pratique	Faux positifs en grand n	Interpréter la taille de l'effet (I de Moran, RR du cluster)
Ne pas justifier le critère de voisinage W	Résultats non reproductibles	Conduire une analyse de sensibilité sur différents W
Ignorer le problème MAUP	Résultats artefactuels	Choisir le niveau administratif pertinent épidémiologiquement
Appliquer KDE à des données agrégées	Pseudo-précision spatiale	KDE uniquement pour données ponctuelles géolocalisées
Comparer des incidences brutes entre zones	Biais de confusion par l'âge/sexe	Standardiser les taux ou utiliser des modèles de régression spatiale

8.2 Check-list de Validation de l'Analyse Spatiale

i Check-list de validation avant publication

- ☐ *Le système de projection est cohérent entre toutes les couches (même CRS).*
- ☐ *La matrice de poids W est justifiée et une analyse de sensibilité a été conduite.*

- □ *Les tests LISA sont corrigés pour les tests multiples (méthode BH ou Bonferroni).*
- □ *Les taux cartographiés sont lissés (EB ou CAR) si des petites zones sont présentes.*
- □ *Le choix de la méthode de discrétisation est justifié et les seuils sont mentionnés.*
- □ *La légende, l'échelle cartographique et la rose des vents sont présentes sur toutes les cartes.*
- □ *La source des données et le fond de carte (GADM, niveau X) sont mentionnés.*
- □ *L'interprétation des clusters est prudente et ne dépasse pas les données observationnelles.*
- □ *Le code R est commenté et reproductible (set.seed fixé, packages versionnés).*
- □ *Les clusters sont décrits quantitativement (RR, population incluse, p-valeur Monte Carlo).*

4bis. Cartographie des Maladies — Traitement Exhaustif

La cartographie sanitaire ne se limite pas aux cartes choroplèthes d'incidence. Elle constitue un langage visuel complet, structuré par des règles sémiographiques rigoureuses, et mobilise de nombreux types cartographiques selon la nature des données et la question épidémiologique. Cette section traite de façon exhaustive l'ensemble des types de cartes utilisées en santé publique, leurs fondements théoriques, leurs implémentations R et leurs limites.

4bis.1 Sémiologie Graphique en Cartographie Sanitaire

La sémiologie graphique, codifiée par Jacques Bertin (1967), est la théorie fondamentale du langage visuel cartographique. Elle distingue les variables visuelles — les propriétés graphiques que l'oeil humain peut percevoir et interpréter de manière ordonnée ou différentielle — et les types de données qu'elles peuvent représenter de façon pertinente. En épidémiologie, violer ces règles produit des cartes trompeuses qui peuvent orienter de mauvaises décisions de santé publique.

Synthèse : Variables visuelles de Bertin et usage épidémiologique

- > *Valeur (clair/foncé) : ordonnée — idéale pour taux continus, incidences, risques relatifs.*
- > *Couleur (teinte) : différentielle — idéale pour types qualitatifs (HH/LL/HL/LH, type de maladie).*
- > *Taille (surface) : ordonnée — idéale pour effectifs absolus (nombre de cas, décès).*
- > *Forme : différentielle — pour distinguer des catégories sur symboles ponctuels.*

-> Grain/texture : ordonnée faible — pour représentations en noir et blanc (publications sans couleur).

-> Règle d'or : la valeur encode les quantités ordonnées ; la couleur encode les catégories ; la taille encode les effectifs absolus.

-> Erreur classique : utiliser une teinte unique (vert -> rouge) pour une variable nominale, ou des couleurs divergentes pour une variable unipolaire.

4bis.2 Taxonomie Complète des Types de Cartes en Santé Publique

4bis.2.1 Principes avancés de la Carte Choroplèthe

La carte choroplèthe est la représentation cartographique la plus répandue en épidémiologie. Trois erreurs fondamentales sont à éviter systématiquement : (1) cartographier des effectifs absolus au lieu de taux, ce qui produit une carte de densité de population ; (2) utiliser une palette séquentielle pour des données divergentes (ex. résidus de modèles, SIR centré sur 1) ; (3) choisir une discrétisation inadaptée. La comparaison des quatre méthodes de classification sur une même variable révèle leur impact visuel considérable.

```
# Comparaison de 4 méthodes de classification – Impact visuel
library(classInt); library(tmap)

methodes <- c('quantile', 'jenks', 'equal', 'sd')
titres    <- c('A. Quantiles', 'B. Jenks', 'C. Intervalles egaux', 'D. Ecart-
type')

cartes_classif <- lapply(seq_along(methodes), function(i) {
  tm_shape(benin_sante) +
    tm_polygons('incidence_palu', style = methodes[i], n = 5,
               palette = 'YlOrRd', border.col = 'white', border.lwd = 0.3,
               title = 'Inc. (pour 1000)') +
  tm_shape(benin_dept) + tm_borders(col = 'black', lwd = 1.0) +
  tm_layout(main.title = titres[i], main.title.size = 0.85)
})
tmap_arrange(cartes_classif[[1]], cartes_classif[[2]],
             cartes_classif[[3]], cartes_classif[[4]], ncol = 2)
tmap_save(tmap_arrange(cartes_classif[[1]], cartes_classif[[2]],
                      cartes_classif[[3]], cartes_classif[[4]], ncol = 2),
          'comparaison_classifications.png', dpi = 300, width = 14, height = 16)
```

4bis.2.2 Cartes de Symboles Proportionnels

Les cartes de symboles proportionnels représentent des effectifs absolus par des symboles dont la superficie est proportionnelle à la valeur. Elles sont préférables aux choroplèthes lorsque l'on souhaite visualiser la charge absolue de morbidité (nombre total de cas, de décès) plutôt que le risque relatif. La combinaison choroplèthe (taux) + symboles proportionnels (effectifs) dans une

même figure permet de distinguer les zones à forte incidence mais faible population des zones à forte charge absolue.

```
# Carte de symboles proportionnels - Charge absolue de paludisme
centroïdes_sf <- st_centroid(benin_sante)

carte_symb <- ggplot() +
  geom_sf(data = benin_sante, fill = 'grey92', color = 'grey60', linewidth =
0.2) +
  geom_sf(data = st_transform(benin_dept, 32631),
    fill = NA, color = 'black', linewidth = 0.9) +
  geom_sf(data = centroïdes_sf,
    aes(size = cas_palu, color = incidence_palu),
    alpha = 0.75, shape = 21, stroke = 0.4) +
  scale_size_area(max_size = 18, name = 'Cas totaux',
    labels = scales::comma) +
  scale_color_gradientn(colors = c('#FFFFB2', '#FD8D3C', '#BD0026'),
    name = 'Incidence (pour 1000)') +
  labs(title = 'Charge absolue et incidence du paludisme - Benin',
    subtitle = 'Taille = effectifs | Couleur = incidence pour 1 000',
    caption = 'Source : DHIS2 Benin, 2024. Fond de carte : GADM.') +
  theme_void() +
  theme(plot.title = element_text(size = 13, face = 'bold', hjust = 0.5),
    legend.position = 'right')
ggsave('carte_symboles_proportionnels.png', carte_symb,
  dpi = 300, width = 9, height = 12, bg = 'white')
```

4bis.2.3 Cartogrammes (Gastner-Newman et Dorling)

Le cartogramme déforme la superficie de chaque unité géographique proportionnellement à une variable statistique (population, nombre de cas). Le cartogramme de Gastner-Newman maintient la contiguïté entre unités, celui de Dorling remplace chaque unité par un cercle proportionnel. Ils corrigent le biais visuel des choroplèthes classiques où les grandes étendues peu peuplées (ex. nord du Bénin) dominant visuellement la carte même si leur incidence est faible.

```
# Cartogrammes - package cartogram
# install.packages('cartogram')
library(cartogram)

# Cartogramme de Gastner-Newman (contigue - conserve la topologie)
carto_gastner <- cartogram_cont(benin_sante, weight = 'population', itermax =
15)

# Cartogramme de Dorling (non contigue - cercles proportionnels)
carto_dorling <- cartogram_dorling(benin_sante, weight = 'population', k = 5)

# Visualisation comparee
p_gastner <- ggplot(carto_gastner) +
  geom_sf(aes(fill = incidence_palu), color = 'white', linewidth = 0.2) +
  scale_fill_gradientn(colors = c('#FFFFB2', '#FD8D3C', '#BD0026'),
    name = 'Incidence (pour 1000)') +
  labs(title = 'A. Cartogramme Gastner-Newman (population)') +
```

```

theme_void()

p_dorling <- ggplot(carto_dorling) +
  geom_sf(aes(fill = incidence_palu), color = 'white') +
  scale_fill_gradientn(colors = c('#FFFFB2', '#FD8D3C', '#BD0026'),
    name = 'Incidence (pour 1000)') +
  labs(title = 'B. Cartogramme de Dorling (population)') +
  theme_void()

p_gastner + p_dorling # patchwork

```

4bis.2.4 Cartes de Risque Relatif Standardisé (SIR/SMR)

Le Ratio d'Incidence Standardisé (SIR) et le Ratio de Mortalité Standardisé (SMR) comparent les cas observés aux cas attendus sous hypothèse de risque uniforme sur le territoire. Un $SIR > 1$ indique un excès de risque par rapport à la référence ; un $SIR < 1$ un déficit. La palette divergente est impérative pour ces cartes, avec le blanc ou le gris représentant la valeur de référence $SIR = 1$.

```

# Calcul et cartographie du SIR (Standardized Incidence Ratio)
lambda_national <- sum(benin_sante$cas_palu) / sum(benin_sante$population)
benin_sante$cas_attendus <- benin_sante$population * lambda_national
benin_sante$sir <- benin_sante$cas_palu / benin_sante$cas_attendus

# Intervalle de confiance 95% du SIR (Byar, 1979)
benin_sante$sir_ic_inf <- qchisq(0.025, 2 * benin_sante$cas_palu) /
  (2 * benin_sante$cas_attendus)
benin_sante$sir_ic_sup <- qchisq(0.975, 2 * (benin_sante$cas_palu + 1)) /
  (2 * benin_sante$cas_attendus)

# Categories SIR pour palette divergente
benin_sante$categorie_sir <- cut(
  benin_sante$sir,
  breaks = c(0, 0.50, 0.75, 0.90, 1.10, 1.25, 1.50, Inf),
  labels = c('< 0,50', '0,50-0,75', '0,75-0,90', 'Reference (0,90-1,10)',
    '1,10-1,25', '1,25-1,50', '> 1,50'), right = FALSE)

palette_sir <- c(
  '< 0,50' = '#08519C', '0,50-0,75' = '#2171B5', '0,75-0,90' = '#6BAED6',
  'Reference (0,90-1,10)' = '#F7F7F7',
  '1,10-1,25' = '#FD8D3C', '1,25-1,50' = '#E31A1C', '> 1,50' = '#800026')

carte_sir <- tm_shape(benin_sante) +
  tm_polygons('categorie_sir', palette = palette_sir,
    title = 'SIR paludisme', border.col = 'white', border.lwd = 0.3) +
  tm_shape(benin_dept) + tm_borders(col = 'black', lwd = 1.2) +
  tm_compass(type = 'arrow', position = c('right', 'top'), size = 2) +
  tm_scale_bar(breaks = c(0,50,100,200), position = c('left', 'bottom')) +
  tm_layout(main.title = "Ratio d'Incidence Standardise (SIR) - Paludisme,
    Benin",
    main.title.size = 1.1, legend.position = c('left', 'bottom'))
print(carte_sir)

```

4bis.2.5 Cartes de Flux et Diffusion Spatiale

Les cartes de flux représentent les mouvements entre localités — déplacements de patients, routes de transmission vectorielle, migrations. Elles sont essentielles en épidémiologie de la diffusion spatiale des maladies infectieuses. Le package `ggplot2` avec `geom_curve()` permet une implémentation directe, avec la largeur et la couleur des flèches proportionnelles à l'intensité du flux.

```
# Carte de flux migratoires / transferts inter-communes
set.seed(2024)
communes_chef <- benin_sante %>%
  group_by(NAME_1) %>% slice_max(population, n = 1) %>% ungroup()

coords_origin <- st_coordinates(st_centroid(benin_sante[1:20,]))
coords_dest <- st_coordinates(st_centroid(communes_chef[1:20,]))
flux_n <- sample(50:500, 20, replace = TRUE)

flux_df <- data.frame(
  x_ori = coords_origin[,1], y_ori = coords_origin[,2],
  x_des = coords_dest[,1], y_des = coords_dest[,2],
  flux = flux_n)

carte_flux <- ggplot() +
  geom_sf(data = benin_sante, fill = 'grey95', color = 'grey70', linewidth =
0.2) +
  geom_sf(data = st_transform(benin_dept, 32631),
    fill = NA, color = 'black', linewidth = 0.8) +
  geom_curve(data = flux_df,
    aes(x = x_ori, y = y_ori, xend = x_des, yend = y_des,
      linewidth = flux, color = flux),
    curvature = 0.25,
    arrow = arrow(length = unit(0.15, 'cm'), type = 'closed'),
    alpha = 0.75) +
  scale_linewidth_continuous(range = c(0.3, 2.5), name = 'Flux (patients)') +
  scale_color_gradient(low = '#AED6F1', high = '#1A5276', name = 'Flux
(patients)') +
  labs(title = 'Flux de reference inter-communaux - Benin (simulation)',
    caption = 'Donnees simulees a des fins pedagogiques') +
  theme_void()
print(carte_flux)
```

4bis.2.6 Cartes Spatio-Temporelles et Animations *gganimate*

Lorsque des données épidémiologiques sont disponibles pour plusieurs périodes temporelles, la cartographie spatio-temporelle permet de visualiser l'évolution de la distribution géographique. Deux approches complémentaires : (1) les séries de cartes statiques juxtaposées (`small multiples`) avec `facet_wrap()` ; (2) les animations générées avec `gganimate`. Les animations sont particulièrement efficaces pour les présentations aux décideurs et les publications numériques.

```
# Small multiples spatio-temporels + Animation gganimate
set.seed(2024)
annees <- 2021:2024
```

```

donnees_long <- lapply(annees, function(an) {
  benin_sante %>%
    mutate(annee = an,
           inc_an = pmax(incidence_palu * (1 - 0.05*(an-2021)) +
                        rnorm(n(), 0, 10), 0))
}) %>% bind_rows()

# Small multiples (4 cartes cote a cote)
carte_4ans <- ggplot(donnees_long) +
  geom_sf(aes(fill = inc_an, color = 'white', linewidth = 0.15) +
  geom_sf(data = st_transform(benin_dept, 32631),
          fill = NA, color = 'black', linewidth = 0.7) +
  facet_wrap(~annee, ncol = 2) +
  scale_fill_gradientn(colors = c('#FFFFB2', '#FD8D3C', '#BD0026'),
                      name = 'Incidence (pour 1000)',
                      limits = range(donnees_long$inc_an)) +
  labs(title = 'Evolution spatio-temporelle du paludisme – Benin (2021-2024)',
       caption = 'Source : DHIS2. Donnees simulees.') +
  theme_void() +
  theme(strip.text = element_text(size = 12, face = 'bold'),
        legend.position = 'bottom')
ggsave('cartes_spatio_temporelles.png', carte_4ans,
       dpi = 300, width = 14, height = 14, bg = 'white')

# Animation avec gganimate
# install.packages(c('gganimate', 'gifski'))
library(gganimate)

anim <- ggplot(donnees_long) +
  geom_sf(aes(fill = inc_an, color = 'white', linewidth = 0.15) +
  geom_sf(data = st_transform(benin_dept, 32631),
          fill = NA, color = 'black', linewidth = 0.7) +
  scale_fill_gradientn(colors = c('#FFFFB2', '#FD8D3C', '#BD0026'),
                      name = 'Incidence (pour 1000)') +
  labs(title = 'Paludisme au Benin – Année : {frame_time}',
       caption = 'Donnees simulees.') +
  theme_void() +
  transition_time(annee) +
  ease_aes('linear')

animate(anim, fps = 2, width = 700, height = 900, renderer = gifski_renderer())
anim_save('evolution_paludisme_benin.gif')

```

4bis.2.7 Cartes de Surveillance Syndromique et Tableaux de Bord Shiny

La surveillance épidémiologique opérationnelle nécessite des cartes dynamiques intégrées dans des tableaux de bord interactifs. Le package shiny combiné à leaflet permet de construire des applications de surveillance cartographique en temps réel. Ces applications permettent aux responsables de santé publique de visualiser la distribution géographique des syndromes sentinelles, les tendances temporelles et les alertes de dépassement de seuil épidémique.

```
# Application Shiny de surveillance cartographique – Structure minimale
```

```
# install.packages('shiny')
library(shiny); library(leaflet); library(dplyr); library(sf)

ui <- fluidPage(
  titlePanel('Tableau de Bord de Surveillance – Benin'),
  sidebarLayout(
    sidebarPanel(
      selectInput('maladie', 'Maladie :',
        choices = c('Paludisme', 'Diarrhees', 'IRA')),
      sliderInput('semaine', 'Semaine epidemiologique :',
        min = 1, max = 52, value = 26, step = 1),
      checkboxInput('hotspots', 'Afficher les hotspots LISA', value = TRUE)
    ),
    mainPanel(leafletOutput('carte_surv', height = 600))
  )
)

server <- function(input, output, session) {
  output$carte_surv <- renderLeaflet({
    benin_wgs84 <- st_transform(benin_sante, 4326)
    pal <- colorQuantile('YlOrRd', domain = benin_wgs84$incidence_palu, n = 5)
    leaflet(benin_wgs84) %>%
      addTiles() %>%
      addPolygons(
        fillColor = ~pal(incidence_palu), fillOpacity = 0.7,
        color = 'white', weight = 0.8,
        popup = ~paste0('<b>', NAME_2, '</b><br>Incidence : ',
          round(incidence_palu, 1), ' pour 1000')) %>%
      addLegend('bottomright', pal = pal, values = ~incidence_palu,
        title = 'Incidence (pour 1000)')
  })
}
# shinyApp(ui, server) # Décommenter pour lancer
```

4bis.2.8 Systèmes de Projection — Guide Complet

Le choix du système de projection est une décision analytique fondamentale. WGS84 (EPSG:4326) pour les échanges et cartes leaflet ; UTM Zone 31N (EPSG:32631) pour les calculs métriques précis sur le Bénin et l'Afrique de l'Ouest ; Lambert Azimuthal Equal Area (LAEA) pour les cartes continentales africaines. L'usage de WGS84 pour les cartes statiques produit une distorsion nord-sud visible, à éviter dans les publications.

```
# Systèmes de projection recommandés pour le Benin —————

benin_wgs84 <- st_transform(benin_commune, crs = 4326) # WGS84 (leaflet)
benin_utm31n <- st_transform(benin_commune, crs = 32631) # UTM Zone 31N
(calculs)
benin_laea <- st_transform(benin_commune,
  crs = '+proj=laea +lat_0=5 +lon_0=20 +x_0=0 +y_0=0') # Afrique

# Verification des unites
cat('WGS84 – Unite :', st_crs(benin_wgs84)$units_gdal, '\n')
cat('UTM 31N – Unite :', st_crs(benin_utm31n)$units_gdal, '\n')
```



```
# Comparaison superficie (toujours utiliser UTM ou LAEA pour les surfaces)
area_wgs84 <- sum(st_area(benin_wgs84))
area_utm31n <- sum(st_area(benin_utm31n))
cat('Superficie WGS84 :', round(as.numeric(area_wgs84), 2), 'degres carre
(inutilisable)\n')
cat('Superficie UTM 31N:', round(as.numeric(area_utm31n)/1e9, 1), 'milliers de
km2\n')
# Attendu : ~114,8 milliers de km2 pour le Benin
```

10. Modeles Spatiaux Avancés — Régression et Interpolation

Les méthodes d'autocorrélation spatiale présentées dans les sections précédentes sont des outils exploratoires. Pour répondre à la question pourquoi — identifier les déterminants des hétérogénéités spatiales tout en contrôlant les effets de confusion — des modèles de régression spatiale sont nécessaires. Cette section présente de façon exhaustive les modèles SAR, SEM, SDM, SLX, les modèles CAR bayésiens (CARBayes/INLA), la régression géographiquement pondérée (GWR) et le krigeage géostatistique.

10.1 Diagnostic Spatial Préalable : Tests de Lagrange Multiplier

Avant d'ajuster un modèle de régression spatiale, il faut diagnostiquer la nature de la dépendance spatiale résiduelle dans le modèle MCO de base. Les tests des multiplicateurs de Lagrange (Anselin, 1988) permettent de distinguer entre dépendance dans la variable dépendante (SAR) et dépendance dans les résidus (SEM). La règle de décision d'Anselin et Florax (1995) est la référence méthodologique.

Règle de décision Anselin & Florax (1995) — Choix SAR vs SEM

1. *LMlag et LMerr non significatifs -> MCO suffisant.*
2. *LMlag significatif seul -> SAR (contagion spatiale dans Y).*
3. *LMerr significatif seul -> SEM (covariables omises spatialement structurées).*
4. *Les deux significatifs, RLMlag > RLMerr -> SAR.*
5. *Les deux significatifs, RLMerr > RLMlag -> SEM.*
6. *Si spillovers sur X attendus -> SDM ou SLX.*
7. *Non-stationnarité des coefficients -> GWR / MGWR (tester avec gwr.monovar).*

```
# Étape 1 : Modele MCO de base
library(spatialreg); library(spdep)

benin_sante$log_inc      <- log(benin_sante$incidence_palu + 1)
benin_sante$log_pop_den <- log(benin_sante$population /
                               benin_sante$superficie_km2 + 1)

modele_ols <- lm(log_inc ~ log_pop_den, data = benin_sante)
summary(modele_ols)

# Étape 2 : Test de Moran sur residus MCO
moran_residus <- lm.morantest(modele_ols, listw = poids_queen)
print(moran_residus)
# p < 0,05 -> residus spatialement autocorrélés -> MCO inadéquat

# Étape 3 : Tests LM pour choix SAR vs SEM
lm_tests <- lm.LMtests(model = modele_ols, listw = poids_queen, test = 'all')
```

```
print(lm_tests)
# LMlag, LMerr, RLMlag, RLMerr – appliquer la règle Anselin & Florax
```

10.2 Modèle SAR — Spatial Autoregressive (Spatial Lag Model)

Le Modèle SAR (Spatial Lag Model) incorpore la valeur spatiale retardée de la variable dépendante : $y = \rho * W * y + X * \beta + \epsilon$. Le paramètre ρ est le coefficient de contagion spatiale. Si $\rho > 0$ et significatif, l'incidence dans une commune est positivement influencée par ses voisines, indépendamment des covariables. ATTENTION : dans le SAR, les effets marginaux ne sont PAS les coefficients β — il faut décomposer en effets directs (feedback), indirects (spillover) et totaux.

```
# Modele SAR (Spatial Lag Model)
modele_sar <- lagsarlm(
  formula = log_inc ~ log_pop_den,
  data     = benin_sante,
  listw    = poids_queen,
  method   = 'eigen',
  quiet    = FALSE
)
summary(modele_sar, Nagelkerke = TRUE)

# Decomposition effets directs / indirects / totaux
# INDISPENSABLE dans le SAR – les betas seuls sont trompeurs
impacts_sar <- impacts(modele_sar, listw = poids_queen, R = 500)
print(summary(impacts_sar, zstats = TRUE, short = TRUE))

# Diagnostic : Moran sur residus SAR
benin_sante$residus_sar <- residuals(modele_sar)
moran.test(benin_sante$residus_sar, poids_queen)
# Objectif : I de Moran des residus non significatif

cat('AIC OLS :', AIC(modele_ols), '\n')
cat('AIC SAR :', AIC(modele_sar), '\n')
```

10.3 Modèle SEM — Spatial Error Model

Le Modèle d'Erreur Spatiale (SEM) traite la dépendance spatiale comme une structure dans les résidus : $y = X * \beta + u$, avec $u = \lambda * W * u + \epsilon$. Lambda capture l'autocorrélation spatiale des résidus due à des covariables omises spatialement structurées (hydrographie, végétation non mesurées). Le SEM produit des estimateurs efficaces là où le MCO produirait des erreurs-standard sous-estimées et des tests trop libéraux.

```
# Modele SEM (Spatial Error Model)
modele_sem <- errorsarlm(
  formula = log_inc ~ log_pop_den,
  data     = benin_sante,
  listw    = poids_queen,
```

```

  etype = 'error',
  method = 'eigen',
  quiet = FALSE
)
summary(modele_sem, Nagelkerke = TRUE)

cat('Lambda (SEM) : ', round(modele_sem$lambda, 4), '\n')
# Lambda > 0 : residus positivement autocorrelés (covariable omise spatiale)

# Test de Moran sur residus SEM
benin_sante$residus_sem <- residuals(modele_sem)
moran.test(benin_sante$residus_sem, poids_queen)

# Tableau comparatif MCO / SAR / SEM
library(flextable)
tab_comp <- data.frame(
  Modele = c('MCO', 'SAR', 'SEM'),
  AIC = round(c(AIC(modele_ols), AIC(modele_sar), AIC(modele_sem)), 2),
  LogLik = round(c(logLik(modele_ols)[1],
                      logLik(modele_sar)[1],
                      logLik(modele_sem)[1]), 2),
  Moran_p = c(
    round(lm.morantest(modele_ols, poids_queen)$p.value, 4),
    round(moran.test(benin_sante$residus_sar, poids_queen)$p.value, 4),
    round(moran.test(benin_sante$residus_sem, poids_queen)$p.value, 4))
)
flextable(tab_comp) %>%
  set_header_labels(Modele='Modele', AIC='AIC', LogLik='Log-vraisemblance',
                    Moran_p='p-val. Moran (residus)') %>%
  theme_booktabs() %>% autofit() %>% bold(part='header') %>%
  set_caption('Tableau comparatif MCO / SAR / SEM – Paludisme Benin')

```

10.4 Modèle de Durbin Spatial (SDM)

Le Modèle de Durbin Spatial (SDM) est la généralisation la plus complète : $y = \rho * W * y + X * \beta + W * X * \theta + \epsilon$. Il intègre un retard de Y (comme SAR) ET des retards des covariables ($W * X$). Cela permet de tester si les covariables des communes voisines influencent l'incidence locale — par exemple, si la couverture vaccinale dans les communes voisines influence l'incidence locale via des effets d'immunité collective. Le SDM englobe SAR et SEM comme cas particuliers testables.

```

# Modele de Durbin Spatial (SDM)
modele_sdm <- lagsarlm(
  formula = log_inc ~ log_pop_den,
  data = benin_sante,
  listw = poids_queen,
  type = 'mixed', # 'mixed' = SDM (lag Y + lag X)
  method = 'eigen',
  quiet = FALSE
)
summary(modele_sdm, Nagelkerke = TRUE)

```

```
# Decomposition des effets SDM
impacts_sdm <- impacts(modele_sdm, listw = poids_queen, R = 500)
print(summary(impacts_sdm, zstats = TRUE, short = TRUE))
# Effet direct   : impact de X_i sur Y_i (feedback compris)
# Effet indirect  : impact de X_j (voisins) sur Y_i (spillover)
# Effet total     : somme direct + indirect

# Tests de restrictions : SDM vs SAR (theta = 0) et SDM vs SEM
lr_sar_sdm <- -2 * (logLik(modele_sar)[1] - logLik(modele_sdm)[1])
cat('LR test SDM vs SAR :', round(lr_sar_sdm, 3),
    ' p-val =', round(pchisq(lr_sar_sdm, df=1, lower.tail=FALSE), 4), '\n')
lr_sem_sdm <- -2 * (logLik(modele_sem)[1] - logLik(modele_sdm)[1])
cat('LR test SDM vs SEM :', round(lr_sem_sdm, 3),
    ' p-val =', round(pchisq(lr_sem_sdm, df=2, lower.tail=FALSE), 4), '\n')
```

10.5 Modèle SLX — Spatially Lagged X

Le modèle SLX intègre uniquement les retards spatiaux des covariables, sans retard de Y ni autocorrélation des résidus : $y = X * \beta + W * X * \theta + \epsilon$. Bien que simple, il a l'avantage d'effets marginaux directement interprétables comme des coefficients ordinaires de régression. LeSage (2014) le recommande comme point de départ lorsque la théorie ne justifie pas clairement un processus de contagion dans la variable dépendante.

```
# Modele SLX (Spatially Lagged X)
modele_slx <- lmSLX(
  formula = log_inc ~ log_pop_den,
  data    = benin_sante,
  listw    = poids_queen,
  Durbin   = TRUE # Inclure W*X pour toutes les covariables
)
summary(modele_slx)

# Test de Moran sur residus SLX
moran.test(residuals(modele_slx), poids_queen)

# Impacts (directs, indirects, totaux) — directement les coefficients dans SLX
impacts(modele_slx, listw = poids_queen)
```

10.6 Régression Géographiquement Pondérée (GWR)

Les modèles SAR/SEM/SDM supposent la stationnarité spatiale des coefficients — les relations entre covariables et variable dépendante sont constantes sur tout le territoire. Cette hypothèse est souvent irréaliste : l'effet de la densité de population sur l'incidence peut différer entre le nord sahélien et le sud côtier du Bénin. La GWR (Fotheringham, Brunson et Charlton, 2002) estime des coefficients locaux pour chaque localisation, pondérés par la proximité géographique.

Formalisation de la GWR

-> $Y_i = \beta_0(u_i, v_i) + \sum_k \beta_k(u_i, v_i) * X_{ik} + \epsilon_i$

-> (u_i, v_i) : coordonnées géographiques de l'unité i .
 -> $\beta_k(u_i, v_i)$: coefficient local estimé à la localisation i .
 -> Estimation par WLS avec matrice de pondération $W(i) = \text{diag}(w_{ij})$.
 -> $w_{ij} = K(d_{ij} / h)$: noyau spatial (gaussien, bisquare) de bande passante h .
 -> h optimal : cross-validation (CV) ou critère AICc.
 -> Résultat : autant de cartes de coefficients que de covariables -> détection de non-stationnarité spatiale.

```
# GWR avec le package GWmodel
# install.packages('GWmodel')
library(GWmodel); library(sp)

# GWmodel nécessite un SpatialDataFrame (sp)
benin_sp <- as(benin_sante, 'Spatial')
benin_sp@data$log_inc <- log(benin_sp@data$incidence_palu + 1)
benin_sp@data$log_pop_den <- log(benin_sp@data$population /
                                benin_sp@data$superficie_km2 + 1)

coords_sp <- coordinates(benin_sp)
dist_matrix <- gw.dist(dp.locat = coords_sp, longlat = FALSE)

# Sélection du bandwidth optimal (AICc)
bw_optim <- bw.gwr(
  formula = log_inc ~ log_pop_den,
  data = benin_sp,
  kernel = 'bisquare',
  adaptive = TRUE, # k voisins adaptatifs
  approach = 'AICc',
  dMat = dist_matrix
)
cat('Bandwidth optimal (nb voisins) :', bw_optim, '\n')

# Ajustement du modèle GWR
modele_gwr <- gwr.basic(
  formula = log_inc ~ log_pop_den,
  data = benin_sp,
  kernel = 'bisquare',
  adaptive = TRUE,
  bw = bw_optim,
  dMat = dist_matrix
)
print(modele_gwr)

# Extraction des coefficients locaux
benin_sante$beta_pop_gwr <- modele_gwr$SDF$log_pop_den
benin_sante$r2_local_gwr <- modele_gwr$SDF$Local_R2

# Cartographie des coefficients locaux
c_beta <- tm_shape(benin_sante) +
  tm_polygons('beta_pop_gwr', style = 'quantile', n = 7,
             palette = '-RdBu', midpoint = 0,
             title = 'beta densite pop (GWR)', border.col = 'white', border.lwd
= 0.3) +
  tm_shape(benin_dept) + tm_borders(col = 'black', lwd = 1.2) +
  tm_layout(main.title = 'Coefficients locaux GWR - beta densite pop',
```

```

    main.title.size = 0.95)

c_r2 <- tm_shape(benin_sante) +
  tm_polygons('r2_local_gwr', style = 'jenks', n = 5,
    palette = 'YlGn', title = 'R2 local (GWR)',
    border.col = 'white', border.lwd = 0.3) +
  tm_shape(benin_dept) + tm_borders(col = 'black', lwd = 1.2) +
  tm_layout(main.title = "Qualite d'ajustement local (R2 GWR)",
    main.title.size = 0.95)

tmap_arrange(c_beta, c_r2, ncol = 2)
tmap_save(tmap_arrange(c_beta, c_r2, ncol = 2),
  'gwr_coefficients.png', dpi = 300, width = 14, height = 10)

# Test de stationnarite (Leung et al., 2000)
# p < 0,05 -> coefficient non stationnaire -> GWR justifiee

```

10.7 Modèle BYM Bayésien avec CARBayes

Le modèle BYM (Besag, York et Mollié, 1991) décompose l'hétérogénéité spatiale en deux composantes : un effet spatial structuré (terme CAR de Besag) et un effet aléatoire non structuré. Cette décomposition distingue le clustering spatial véritable du bruit aléatoire non spatial. Le paramètre lambda de Lee (2013) mesure la fraction de variance expliquée par la composante spatiale (0 = tout non structuré ; 1 = tout spatial).

Modele de Poisson BYM — Formalisation

-> $Y_i | \mu_i \sim \text{Poisson}(E_i * \exp(\eta_i))$ ou $E_i = \text{cas attendus}$
 -> $\eta_i = \mu + \phi_i + \theta_i$
 -> ϕ_i = composante spatiale structuree (ICAR de Besag)
 -> $\theta_i \sim N(0, \sigma^2_{\theta})$: composante non structuree
 -> $\phi_i | \phi_{-i} \sim N(\text{somme}_{\{j \sim i\}} \phi_j / n_i, \sigma^2_{\phi} / n_i)$
 -> Package R : CARBayes (Lee, 2013) — inference bayesienne MCMC.

```

# Modele BYM avec CARBayes
# install.packages('CARBayes')
library(CARBayes)

# Matrice de voisinage W (binaire)
W_mat <- nb2mat(voisins_queen, style = 'B', zero.policy = TRUE)

# Modele BYM
modele_bym <- S.CARbym(
  formula = cas_palu ~ offset(log(cas_attendus)),
  data = as.data.frame(benin_sante),
  family = 'poisson',
  W = W_mat,
  burnin = 20000,
  n.sample = 100000,
  thin = 10,
  verbose = TRUE

```

```

)
print(modele_bym$summary.results)

# Relative Risk lisse bayésien
benin_sante$rr_bym <- modele_bym$fitted.values / benin_sante$cas_attendus

# Fraction de variance spatiale (lambda de Lee)
cat('Fraction spatiale (lambda) :',
    round(modele_bym$model$fit['lambda'], 3), '\n')

# Cartographie du RR bayésien
benin_sante$cat_rr_bym <- cut(benin_sante$rr_bym,
    breaks = c(0, 0.5, 0.75, 0.9, 1.1, 1.25, 1.5, Inf),
    labels = c('< 0,50','0,50-0,75','0,75-0,90','Reference',
        '1,10-1,25','1,25-1,50','> 1,50'))

palette_bym <- c('< 0,50'='#08519C','0,50-0,75'='#2171B5','0,75-0,90'='#6BAED6',
    'Reference'='#F7F7F7','1,10-1,25'='#FD8D3C','1,25-1,50'='#E31A1C','>
1,50'='#800026')

carte_bym <- tm_shape(benin_sante) +
    tm_polygons('cat_rr_bym', palette = palette_bym,
        title = 'RR BYM', border.col = 'white', border.lwd = 0.3) +
    tm_shape(benin_dept) + tm_borders(col = 'black', lwd = 1.2) +
    tm_layout(main.title = 'Risque Relatif BYM (CARBayes) – Paludisme Benin',
        main.title.size = 1.0, legend.position = c('left','bottom'))
print(carte_bym)

```

10.8 Modèle BYM2 avec R-INLA

R-INLA (Integrated Nested Laplace Approximation) est la référence pour l'inférence bayésienne rapide dans les modèles hiérarchiques à champ spatial gaussien. Le modèle BYM2 (Riebler et al., 2016) est une reparamétrisation du BYM original : le paramètre ϕ représente la proportion de variance totale expliquée par la composante spatiale structurée. R-INLA est 10 à 100 fois plus rapide que CARBayes pour des données de grande taille.

```

# Modele BYM2 avec R-INLA
# install.packages('INLA', repos='https://inla.r-inla-download.org/R/stable')
library(INLA)

# Preparation du graphe de voisinage pour INLA
nb2INLA('benin_nb.graph', voisins_queen)
g <- inla.read.graph('benin_nb.graph')

benin_sante$id_area <- 1:nrow(benin_sante)

# Formule BYM2 avec prior PC (Penalized Complexity – Simpson et al. 2017)
formule_bym2 <- cas_palu ~ 1 + log_pop_den +
    f(id_area, model = 'bym2', graph = g,
        hyper = list(
            prec = list(prior = 'pc.prec', param = c(0.5, 0.01)),

```



```

    phi = list(prior = 'pc',      param = c(0.5, 2/3))
  ))

# Ajustement INLA
inla_bym2 <- inla(
  formula      = formule_bym2,
  family       = 'poisson',
  data         = as.data.frame(benin_sante),
  E            = cas_attendus,
  control.compute = list(dic = TRUE, waic = TRUE, cpo = TRUE),
  control.predictor = list(compute = TRUE)
)
summary(inla_bym2)

# Extraction du risque relatif posterieur
benin_sante$rr_inla      <- inla_bym2$summary.fitted.values$mean /
  benin_sante$cas_attendus
benin_sante$rr_inla_025  <- inla_bym2$summary.fitted.values[, '0.025quant'] /
  benin_sante$cas_attendus
benin_sante$rr_inla_975  <- inla_bym2$summary.fitted.values[, '0.975quant'] /
  benin_sante$cas_attendus

# Carte du RR posterieur INLA-BYM2
carte_inla_bym2 <- tm_shape(benin_sante) +
  tm_polygons('rr_inla', style = 'fixed',
    breaks = c(0, 0.7, 0.9, 1.1, 1.3, 1.5, Inf),
    palette = '-RdBu', midpoint = 1,
    title = 'RR posterieur INLA',
    border.col = 'white', border.lwd = 0.3) +
  tm_shape(benin_dept) + tm_borders(col = 'black', lwd = 1.2) +
  tm_layout(main.title = 'Risque Relatif Bayesien (INLA-BYM2) - Paludisme',
    main.title.size = 1.0, legend.position = c('left', 'bottom'))
print(carte_inla_bym2)

```

10.9 Krigeage et Interpolation Géostatistique

Le krigeage est une méthode d'interpolation spatiale géostatistique qui prédit les valeurs d'une variable en des localisations non observées, en tenant compte de la structure de corrélation spatiale (variogramme). En épidémiologie, il est utilisé pour interpoler des prévalences à partir d'enquêtes ponctuelles, produire des surfaces continues de risque, et cartographier des expositions environnementales (température, pluviométrie) sur tout le territoire. Le variogramme — outil central du krigeage — décrit comment la variance entre deux points évolue en fonction de leur distance.

```

# Krigeage ordinaire avec gstat
# install.packages('gstat')
library(gstat); library(sf)

# Simulation de donnees ponctuelles (enquete de prevalence palustre)
set.seed(2024)
n_pts <- 60

```

```

benin_wgs84_un <- st_union(st_transform(benin_commune, 4326))
pts_enquete <- st_sample(benin_wgs84_un, size = n_pts)
pts_df <- st_as_sf(data.frame(geometry = pts_enquete))
pts_df$prevalence <- rnorm(n_pts, mean = 25, sd = 12), 0)

# Reprojection UTM pour krigeage metrique
pts_utm <- st_transform(pts_df, 32631)
pts_sp <- as(pts_utm, 'Spatial') # gstat nécessite sp

# Variogramme empirique
vgm_emp <- variogram(prevalence ~ 1, data = pts_sp)
plot(vgm_emp, main = 'Variogramme empirique - Prevalence palustre')

# Ajustement du variogramme theorique (spherique)
vgm_fit <- fit.variogram(
  vgm_emp,
  model = vgm(psill = 150, # Palier (sill)
              model = 'Sph', # Spherique
              range = 200000, # Portee en metres (200 km)
              nugget = 20) # Effet pepite
)
print(vgm_fit)
plot(vgm_emp, vgm_fit, main = 'Variogramme ajuste (spherique)')

# Grille d'interpolation sur le Benin (resolution 10 km)
benin_utm <- st_transform(benin_commune_proj, 32631)
grille_sf <- st_make_grid(benin_utm, cellsize = 10000, what = 'centers') %>%
  st_as_sf() %>%
  .[st_within(., st_union(benin_utm), sparse = FALSE)[,1], ]
grille_sp <- as(grille_sf, 'Spatial')

# Krigeage ordinaire
krige_result <- krige(
  formula = prevalence ~ 1,
  locations = pts_sp,
  newdata = grille_sp,
  model = vgm_fit
)

grille_sf$prev_krigeee <- krige_result$var1.pred
grille_sf$ecart_type <- sqrt(krige_result$var1.var)

# Carte prevalence krigeee + incertitude
c_krig <- ggplot() +
  geom_sf(data = grille_sf, aes(color = prev_krigeee), size = 0.8) +
  scale_color_gradientn(colors = c('#FFFFB2', '#FD8D3C', '#BD0026'),
                        name = 'Prevalence (%) - Krigeee') +
  geom_sf(data = st_transform(benin_dept, 32631),
          fill = NA, color = 'black', linewidth = 0.8) +
  labs(title = 'Surface de prevalence krigeee - Paludisme, Benin',
       subtitle = 'Krigeage ordinaire, variogramme spherique, resolution 10 km',
       caption = 'Methode : krige (gstat). Donnees simulees.') +
  theme_void()

c_sd <- ggplot() +
  geom_sf(data = grille_sf, aes(color = ecart_type), size = 0.8) +

```

```

scale_color_viridis_c(option = 'magma', name = 'Ecart-type krigage') +
geom_sf(data = st_transform(benin_dept, 32631),
        fill = NA, color = 'black', linewidth = 0.8) +
labs(title = 'Incertitude du krigage (ecart-type)',
     subtitle = 'Zones a forte incertitude = données insuffisantes') +
theme_void()

c_krig + c_sd # patchwork

```

10.10 Tableau Comparatif de Tous les Modèles Spatiaux

Le tableau suivant synthétise l'ensemble des modèles spatiaux présentés dans ce guide, avec leurs hypothèses, les tests préalables à leur utilisation, et leurs packages R de référence. Ce tableau est conçu pour servir d'aide à la décision lors du choix du modèle.

Guide de selection du modele spatial — Synthèse décisionnelle

- > MCO + Moran residus non significatif : MCO suffisant.
- > LMlag significatif seul : SAR (lagsarlm, spatialreg).
- > LMerr significatif seul : SEM (errorsarlm, spatialreg).
- > Spillovers sur X attendus : SDM (lagsarlm type='mixed') ou SLX (lmSLX).
- > Coefficients non stationnaires (gwr.monovar $p < 0,05$) : GWR (GWmodel).
- > Cartographie du risque avec quantification d'incertitude : INLA-BYM2.
- > Données ponctuelles a interpoler : Krigeage (gstat).
- > Règle universelle : toujours vérifier les résidus avec test de Moran apres ajustement.

11. Conclusion

La géoépidémiologie et l'analyse spatiale constituent aujourd'hui des outils incontournables de la santé publique moderne. Elles permettent de transformer des données de routine — collectées dans les systèmes d'information sanitaire comme le DHIS2, les enquêtes ménages ou les études de cohorte — en cartes et en indicateurs spatiaux qui révèlent des patterns épidémiologiques inaccessibles à l'analyse tabulaire classique. Dans le contexte africain et béninois en particulier, où les ressources de santé sont contraintes et où les maladies à fort gradient spatial comme le paludisme, les maladies diarrhéiques et les infections respiratoires persistent, la priorisation spatiale des interventions de santé publique est une nécessité stratégique.

Ce guide a couvert les trois piliers de l'analyse géoépidémiologique avec R : la cartographie sanitaire à partir de données GADM via le package `gadm`, incluant les cartes choroplèthes avec `tmap` et `ggplot2`, les cartes interactives `leaflet` et le lissage bayésien empirique pour la cartographie du risque ; l'autocorrélation spatiale globale avec l'indice de Moran global (test asymptotique et permutation Monte Carlo, diagramme de Moran) et l'autocorrélation locale avec les statistiques LISA de décomposition, leur cartographie et leur interprétation par quadrant ; et la détection de clusters et hotspots avec la statistique de Getis-Ord G_i^* , le lissage par noyau spatial (KDE) pour les données ponctuelles, et la méthode de Kulldorff pour la détection formelle de clusters circulaires avec test de signification par simulation Monte Carlo.

Plusieurs points méritent une attention particulière dans la pratique. La matrice de poids spatiaux W est une décision analytique fondamentale qui doit être justifiée et soumise à une analyse de sensibilité. Les tests multiples inhérents aux statistiques LISA doivent systématiquement être corrigés, idéalement par la méthode Benjamini-Hochberg qui contrôle le taux de faux positifs sans être aussi conservatrice que la correction de Bonferroni. Les taux bruts dans les petites zones doivent être lissés avant cartographie, le lissage empirique bayésien spatial étant la méthode de référence. Enfin, l'interprétation des clusters spatiaux doit rester prudente : la détection d'un cluster est une observation épidémiologique qui génère des hypothèses à tester ; elle n'établit pas de relation causale.

L'écosystème R — `gadm`, `sf`, `spdep`, `sfdep`, `tmap`, `ggplot2`, `leaflet`, `KernSmooth`, `SpatialEpi` et `spatialreg` — fournit un cadre analytique cohérent, gratuit, reproductible et de niveau international qui couvre l'intégralité du cycle de l'analyse géoépidémiologique. Pour approfondir, le lecteur est invité à explorer les modèles conditionnellement autorégressifs (CAR) avec le package `CARBayes`

pour la modélisation bayésienne du risque spatial, la régression géographiquement pondérée (GWR) avec le package GWmodel pour la modélisation de la non-stationnarité spatiale, et les méthodes d'interpolation spatiale (krigeage) avec le package gstat pour la prédiction spatiale continue.

Références Bibliographiques

- Anselin, L. (1995). Local indicators of spatial association — LISA. *Geographical Analysis*, 27(2), 93–115.
- Bivand, R. S., Pebesma, E., & Gómez-Rubio, V. (2013). *Applied Spatial Data Analysis with R* (2nd ed.). Springer, New York.
- Getis, A., & Ord, J. K. (1992). The analysis of spatial association by use of distance statistics. *Geographical Analysis*, 24(3), 189–206.
- Kulldorff, M. (1997). A spatial scan statistic. *Communications in Statistics — Theory and Methods*, 26(6), 1481–1496.
- Lovelace, R., Nowosad, J., & Muenchow, J. (2019). *Geocomputation with R*. CRC Press. Disponible en ligne : geocompr.robinlovelace.net
- Marshall, R. J. (1991). Mapping disease and mortality rates using empirical Bayes estimators. *Journal of the Royal Statistical Society Series C*, 40(2), 283–294.
- Pebesma, E. (2018). Simple features for R: standardized support for spatial vector data. *The R Journal*, 10(1), 439–446.
- Tennekes, M. (2018). tmap: Thematic maps in R. *Journal of Statistical Software*, 84(6), 1–39.
- Tobler, W. R. (1970). A computer movie simulating urban growth in the Detroit region. *Economic Geography*, 46(S1), 234–240.

Document rédigé avec R Markdown — Avril 2026

Auteur : Lionel AGOSSOU | Épidémiologiste | Biostatisticien | Formateur en Analyse de Données Biomédicales